

UNIVERSIDAD DE GUADALAJARA,
CENTRO UNIVERSITARIO DE CIENCIAS EXACTAS E INGENIERÍAS
DIVISIÓN DE INGENIERÍAS



**Identificación de modos de oscilación electromecánicos mediante
una técnica de Tufts-Kumaresan multivariable**

TESIS QUE PARA OBTENER EL GRADO DE
Maestro en Ciencias en Ingeniería Eléctrica

PRESENTA

Ing. Glader David Hernández Reyes

DIRECTOR DE TESIS

Dr. José de Jesús Nuño Ayon

CODIRECTOR DE TESIS

Dr. Nombre del Codirector

Guadalajara, Jalisco, Junio 2026

DEDICATORIA

A mi familia y a mi país.

AGRADECIMIENTOS

agradezco a toda la evolución de la humanidad que me ha llevado hasta aquí.

ÍNDICE GENERAL

DEDICATORIA	IX
AGRADECIMIENTOS	XI
ÍNDICE GENERAL	XIII
ÍNDICE DE FIGURAS	XIV
ÍNDICE DE TABLAS	XV

CAPITULO 1

INTRODUCCIÓN	1
1.1. Antecedentes	2
1.1.1. Técnicas de análisis multivariantes	3
1.2. Justificación	4
1.3. Objetivos	5
1.3.1. General	5
1.3.2. Específicos	5
1.4. Hipótesis	6
1.5. Metodología	6
1.6. Cronograma	7
Referencias	8

CAPITULO 2

MARCO TEÓRICO	11
2.1. Introducción del Capítulo	11
2.1.1. Dinámica de Oscilaciones Electromecánicas	12
2.2. Formulación Discreta y Predicción Lineal	15
2.2.1. Del Tiempo Continuo al Dominio Muestreado	15
2.3. Algoritmo Tufts-Kumaresan Multivariable (Multi-TK)	16
2.3.1. Modelo de Señal y Predicción Lineal hacia Atrás	16

2.3.2.	Sistema Global Multicanal	17
2.3.3.	Descomposición SVD y Selección del Orden del Modelo	17
2.3.4.	Truncamiento de la SVD y Solución del Sistema	18
2.4.	Patrones Dinámicos: Formas Modales y Factores de Participación	19
2.4.1.	Estimación de Amplitudes Complejas	19
2.4.2.	Discriminación de Modos Dominantes por Energía Modal	19
2.4.3.	Forma Modal (Mode Shape)	20
2.4.4.	Factor de Participación	21
2.4.5.	Identificación de Grupos Coherentes: Coseno Director y Agrupa- miento Espectral	22
Referencias		23

CAPITULO 3

RESULTADOS	25
-----------------------------	-----------

ÍNDICE DE FIGURAS

1.1. Clasificación de Técnicas Multivariantes (WAMS)	5
--	---

ÍNDICE DE TABLAS

1.1. Cronograma de actividades (Agosto 2025 - Diciembre 2026)	7
---	---

CAPITULO 1

INTRODUCCIÓN

Desde finales del siglo XIX, Thomas A. Edison comenzó con el trabajo de electrificación, creando por primera vez, una red eléctrica de corriente continua (CC) en New York en 1882, la estación Pearl Street generaba 30 kW a 110 Volts para un total de 59 clientes. Luego, Nikola Tesla hizo publicaciones sobre las ventajas de la corriente alterna (CA), que describen motores de inducción y síncronos de dos fases. En 1891 se puso en marcha la primera red eléctrica trifásica de CA en Alemania, transmitiendo energía a 179 km a 12 kV. Para Estados Unidos en 1893 se puso la primera red eléctrica de CA en California, una red de 12 km a 2.3 kV [1]. En México, la primera red eléctrica se deriva de una fábrica de tejidos en la ciudad de León, Guanajuato en 1879, y en menos de 10 años se tenía una capacidad instalada en todo México de 937.89 kW en 60 estaciones eléctricas [2].

Con el paso de las décadas, estas pequeñas redes eléctricas fueron evolucionando gradualmente, hasta llegar a ser las grandes redes eléctricas interconectadas, incluso internacionalmente, que conocemos hoy en día. Estas grandes redes son la infraestructura más grande de la sociedad moderna. Por lo que la red eléctrica puede ser definida como el conjunto de cables y máquinas que conectan las fuentes de electricidad (las estaciones de energía) con los clientes y la infinidad de diferentes usos [3]. Usualmente estas grandes redes están fuertemente interconectadas, por lo que una falla lo suficientemente severa genera grandes problemas a lo largo de toda la red interconectada. En este contexto podemos definir la estabilidad del sistema eléctrico como la capacidad del sistema de mantener su estado de operación sin mayores desviaciones en las variables eléctricas (voltaje, frecuencia, ángulo de fase), tras haber sido sometido a una falla o perturbación en la red [4], [5].

A lo largo de la historia, las vulnerabilidades de las grandes redes interconectadas se han hecho evidentes debido a los grandes apagones que han ocurrido en diferentes regiones del mundo. En Estados Unidos por ejemplo, los cortes de energía y las perturbaciones en la red eléctrica cuestan anualmente entre 75,000 y 180,000 millones de dólares [3]. Las diferentes fallas consecutivas durante los últimos 40 años ponen en evidencia la vulnerabilidad y la necesidad de comprender los fenómenos de estabilidad, para el desarrollo de controles y la restauración de la red. Para poder diseñar estas medidas, es necesario clasificar los diferentes

tipos de estabilidad, dependiendo de la naturaleza física del fenómeno de inestabilidad, el tamaño de la perturbación, los dispositivos, procesos y el tiempo involucrado. Una de las categorías recae en la estabilidad del rotor, la cual se puede definir como la capacidad de las máquinas síncronas interconectadas de mantener sincronismo entre sí después de sufrir algún disturbio [4], [5]. Estas perturbaciones desbalancean el par mecánico y eléctrico de las máquinas síncronas, dando lugar a oscilaciones de baja frecuencia (LFOs) que pueden ser amortiguadas o no, dependiendo de las características del sistema. Las LFOs se pueden ver como modos (frecuencia y amortiguamiento de la oscilación) electromecánicos de oscilación, y dependiendo de su naturaleza pueden causar inestabilidad en el sistema eléctrico de potencia. Los modos se clasifican como locales (1 a 2 Hz) o inter-área (0.2 a 1 Hz), dependiendo de la ubicación de las máquinas involucradas en la oscilación. Los modos locales involucran a una o pocas máquinas en una misma área geográfica, mientras que los modos inter-área involucran a grupos de máquinas en diferentes áreas geográficas que oscilan entre sí. El detectar y mitigar estos modos mediante las mediciones disponibles surge como una herramienta crucial para garantizar la estabilidad y confiabilidad.

La necesidad de un monitoreo de la dinámica del sistema en tiempo real es más crucial que nunca. Los sistemas tradicionales de supervisión (por sus siglas en inglés SCADA) son insuficientes para el análisis dinámico, debido a sus bajas tasas de muestreo y la falta de sincronización temporal entre mediciones distantes. La verdadera revolución tecnológica en este ámbito ha sido el desarrollo de las Unidades de Medición Fasorial (PMU) y su integración en Sistemas de Monitoreo de Área Amplia (WAMS) [6]. Las PMUs proporcionan mediciones de alta velocidad (e.g., 30-120 Hz) de fasores de voltaje y corriente, crucialmente sincronizadas mediante una marca de tiempo global (GPS), ofreciendo un análisis del estado dinámico del sistema.

Este trabajo se alinea con los lineamientos de la Secretaría de Ciencia, Humanidades, Tecnología e Innovación (Secihti) bajo el Eje de Cambio Climático y Gestión de Riesgos, buscando fortalecer las capacidades tecnológicas del Estado mexicano en el sector energético.

1.1 ANTECEDENTES

La disponibilidad de flujos de datos de PMUs abre dos vías principales para el análisis modal: el análisis de datos ambientales (ambient data) durante la operación normal y el análisis de ringdown tras una perturbación severa [7]. Por ejemplo, las fallas grandes en la red generan una aceleración en los rotores de los generadores, produciendo así una desviación en la frecuencia del sistema y otras mediciones eléctricas, por ejemplo, el flujo de potencia, voltaje, entre otras.

La clasificación de los análisis transitorios para estimar los modos de oscilación se

subdividen en un principio en métodos lineales y no lineales. Los métodos no lineales se subdividen a su vez en métodos paramétricos y no paramétricos. Los métodos paramétricos hacen la identificación de un modelo matemático del sistema y así determinan valores instantáneos de frecuencia y amortiguamiento, mientras que los métodos no paramétricos usan técnicas en el dominio de la frecuencia, como la transformada de Fourier, para estimar los modos de oscilación. Por otro lado, los métodos lineales se aplican la suposición de que los modos de oscilación no varían significativamente durante el periodo de análisis. Estas técnicas hacen un ajuste de curvas y se subdividen en dos clases: las técnicas del dominio del tiempo y las técnicas del dominio de la frecuencia. Las técnicas del dominio de la frecuencia como la identificación en el dominio de la frecuencia o identificación por la transformada Z, ajustan el modelo basado en el espectro de la frecuencia de los datos medidos. Por otro lado, las técnicas del dominio del tiempo, como lo son Prony, Algoritmo de Realización del Sistema Propio y Matrix Pencil, basan su estimación en la matriz de Hankel, una matriz cuadrada construida que ventanea los datos medidos en el tiempo [7].

1.1.1 TÉCNICAS DE ANÁLISIS MULTIVARIABLES

Técnicas como Prony para múltiples señales como en [8], establecen un enfoque multivariable para el análisis modal, lo que mejora la exactitud con la que se estiman los parámetros. Los métodos que basan el análisis en una señal presentan menores ventajas en comparación con los métodos multivariables, ya que de una sola señal no se pueden extraer los patrones dinámicos globales del sistema, y en ocasiones los modos de oscilación pueden no ser observables en ciertas señales. Por lo que los métodos multivariables presentan una ventaja significativa al aprovechar la información contenida en múltiples señales medidas en diferentes ubicaciones del sistema eléctrico de potencia.

Después de Prony multivariable [8], en 2007 el doctor Messina y colegas mediante funciones ortogonales empíricas aplican la SVD a la matriz de datos para extender los patrones propios y temporales de mayor energía [9]. Una técnica que reduce el tiempo de cómputo usando las mismas funciones empíricas ortogonales se presenta en [10]. En 2012 se realiza una extensión que no solo proporciona la variabilidad temporal de la oscilación de baja frecuencia, sino que también calcula la distribución espacial de los modos de oscilación polarizados (POM) relevantes sin necesidad de experiencia previa del sistema [11]. 2014 fue el año para una expansión multivariable basada en un análisis de Fourier para datos ringdowns, aquí se aplican las tendencias de las oscilaciones observadas en los picos de amplitud en el dominio de la frecuencia, usando la FFT [12].

En 2015, el doctor Barocio y colegas mediante una descomposición dinámica de modos (DMD) aproximan el operador de Koopman global, aproximando funciones de Koopman utilizando dos conjuntos de secuencias de datos ordenadas temporalmente [13]. En 2016, se usan técnicas de reducción lineal más avanzados que analizan la geometría del manifold

formado por todos los datos del sistema en un espacio de alta resolución [14]. Para 2017 se propone una respuesta directa a la falla de observabilidad del CWT estándar, combinando la información de todos los canales antes de la estimación para encontrar modos que podrían estar ocultos en canales individuales [15]. En 2019 una extensión MIMO del Vector Fitting es aplicada para múltiples señales simultáneas [16], [17].

Más recientemente, en 2022, el doctor Zamora-Méndez propone una descomposición iterativa de valores propios basado en una extensión de las matrices de Hankel para múltiples señales [18] y en 2024 Rodríguez-Soto, E. Barocio y colaboradores extendieron el método DMD multivariable que utiliza una corrección espacio-temporal entre PMUs para mejorar los datos faltantes y outliers utilizando las distancias de Mahalanobis [19]. En el año actual, técnicas como el análisis independiente de componentes rápido (FastICA) junto con el algoritmo de búsqueda de coincidencias no lineal (NMP) ayuda a la mejora de estimación de parámetros modales a partir de datos contaminados con ruido [20].

Esta realidad ha impulsado una intensa investigación en métodos de identificación modal basados en mediciones (data-driven) que procesan todas las señales de WAMS simultáneamente en una gran matriz de datos. La clasificación presentada en la Fig. 1.1 no es meramente descriptiva, sino que revela la evolución lógica y las limitaciones actuales de la tecnología. Se observa una clara diferencia histórica: por un lado, las técnicas paramétricas clásicas (Rama 5, e.g., Prony) ofrecen alta resolución espectral pero sufren ante el ruido; por otro lado, las técnicas de subespacio y geométricas (Ramas 3 y 4, e.g., ERA, SSI, DMD) manejan mejor la dimensionalidad global pero imponen una carga computacional que dificulta su aplicación en tiempo real estricto. Es aquí donde cobra relevancia la identificación de un campo tecnológico específico. Mientras que los métodos híbridos recientes (Rama 1) se enfocan en el pre-filtrado (Bessel) o la descomposición iterativa (IEVDHM), existe un vacío en la literatura respecto a la adaptación multivariable de métodos paramétricos robustos.

1.2 JUSTIFICACIÓN

La creciente integración de recursos energéticos renovables y la operación de los sistemas de potencia cerca de sus límites de estabilidad han aumentado la naturaleza no lineal de las oscilaciones. Los métodos actuales de monitoreo enfrentan desafíos críticos que justifican el desarrollo de una nueva metodología capaz de procesar información de manera robusta y global.

En este contexto, la presente investigación se alinea estratégicamente con el Programa Nacional Estratégico (PRONACE) bajo el Eje Estratégico de Cambio Climático y Gestión de Riesgos, contribuyendo directamente al desarrollo de modelos tecnológicos de bajo consumo de energía aplicados a la ciudad. La transición hacia un modelo energético




Figura 1.1: Clasificación de Técnicas Multivariantes (WAMS)

sustentable requiere la ampliacion en gran medida de las redes inteligentes (Smart Grids) y la integración de micro-redes y generación renovable. Sin embargo, la intermitencia de estas fuentes limpias introduce dinámicas complejas que amenazan la confiabilidad del suministro. El algoritmo multivariable propuesto actúa como una propuesta tecnológica, pues al garantizar un monitoreo preciso de la estabilidad transitoria, permite operar estas redes modernas de manera segura y eficiente.

1.3 OBJETIVOS

1.3.1 GENERAL

Desarrollar y proponer un método de identificación y analisis modal robusto y eficiente para sistemas de monitoreo de área amplia (WAMS), basado en la extensión multivariable del algoritmo Tufts-Kumaresan [21] [22].

1.3.2 ESPECÍFICOS

- Formular matemáticamente la extensión de la matriz de predicción lineal hacia atrás del método Kumaresan-Tufts para soportar entradas de múltiples señales (MIMO).

- Implementar estrategias de truncamiento adaptativo de valores singulares para discriminar automáticamente entre los modos dominantes del sistema y el ruido de medición no correlacionado.
- Validar el desempeño del algoritmo propuesto mediante señales sintéticas y simulaciones de sistemas de potencia de prueba, comparando su precisión y tiempo de ejecución frente a métodos clásicos como Prony Multiseñal, ERA y Matrix Pencil bajo diferentes escenarios de ruido.
- Estimar las amplitudes y fases de los modos identificados para caracterizar completamente la dinámica electromecánica del sistema. Graficar y visualizar las formas modales y factores de participación.
- Proponer un entorno visual interactivo para el análisis y monitoreo en tiempo real de los modos electromecánicos

1.4 HIPÓTESIS

Con una extensión multivariable de la técnica Tufts-Kumaresan (M-TK), mediante una descomposición de valores singulares recursiva, se espera la identificación unificada de modos electromecánicos con una robustez y una eficiencia computacional apta para el monitoreo en tiempo real.

1.5 METODOLOGÍA

- Revisión bibliográfica y estado del arte: Análisis de técnicas de identificación modal para sistemas de potencia.
- Selección e implementación de algoritmos: Selección de técnicas multivariadas representativas (ERA, Prony multivariable, etc.). Implementación computacional de los algoritmos seleccionados
- Desarrollo de casos de estudio: Creación de modelos de simulación en software especializado (MATLAB/Simulink, DigSILENT, etc.). Diseño de escenarios con diferentes tipos de perturbaciones y condiciones operativas.
- Validación y evaluación: Pruebas de los algoritmos con datos sintéticos y reales. Comparación del desempeño entre métodos multivariados. Análisis de sensibilidad frente a ruido y posiblemente missing data o outliers.
- Análisis de resultados: Análisis estadístico de los resultados obtenidos. Elaboración de conclusiones y recomendaciones.

REFERENCIAS

- [1] J. D. Glover, M. S. Sarma, T. J. Overbye y A. Birchfield, *Power System Analysis and Design*, 6.^a ed. Boston, MA: Cengage Learning, 2017.
- [2] E. de la Garza Toledo, J. Melgoza y L. de la Garza, *Historia de la industria eléctrica*, 1.^a ed. México: Universidad Autónoma Metropolitana, 1994.
- [3] M. Amin y J. Stringer, «The Electric Power Grid: Today and Tomorrow,» *MRS Bulletin*, vol. 33, n.º 4, págs. 347-354, 2008.
- [4] P. Kundur et al., «Definition and Classification of Power System Stability IEEE/CIGRE Joint Task Force on Stability Terms and Definitions,» *IEEE Transactions on Power Systems*, vol. 19, n.º 3, págs. 1387-1401, 2004.
- [5] N. Hatziaargyriou et al., «Definition and Classification of Power System Stability - Revisited & Extended,» *IEEE Transactions on Power Systems*, vol. 36, n.º 4, págs. 3271-3281, 2021.
- [6] J. F. Hauer, D. J. Trudnowski y J. G. DeSteese, «A Perspective on WAMS Analysis Tools for Tracking of Oscillatory Dynamics,» en *IEEE Power Engineering Society General Meeting*, 2007.
- [7] J. Thambirajah, E. Barocio y N. F. Thornhill, «Comparative review of methods for stability monitoring in electrical power systems and vibrating structures,» *IET Generation, Transmission and Distribution*, vol. 4, n.º 10, págs. 1086-1103, 2010.
- [8] D. J. Trudnowski, J. M. Johnson y J. F. Hauer, «Making Prony analysis more accurate using multiple signals,» *IEEE Transactions on Power Systems*, vol. 14, n.º 1, págs. 226-231, 1999.
- [9] A. R. Messina y V. Vittal, «Extraction of Dynamic Patterns From Wide-Area Measurements Using Empirical Orthogonal Functions,» *IEEE Transactions on Power Systems*, vol. 22, n.º 2, págs. 682-692, 2007.
- [10] P. E. Prado, C. E. Castañeda y F. Jurado, «Partitioned modal extraction applied to power system wide-area measurements using empirical orthogonal functions,» *Electric Power Systems Research*, vol. 123, págs. 185-191, 2015.
- [11] D. Yang, C. Rehtanz, Y. Li y D. Cai, «Identification of dominant oscillation mode using complex singular value decomposition method,» *Electric Power Systems Research*, vol. 83, n.º 1, págs. 227-236, 2012.
- [12] Z. Tashman, H. Khalilinia y V. Venkatasubramanian, «Multi Dimensional Fourier Ringdown Analysis for Power Systems Using Synchrophasors,» *IEEE Transactions on Power Systems*, vol. 29, n.º 2, págs. 731-741, 2014.

- [13] E. Barocio, B. C. Pal, N. F. Thornhill y A. R. Messina, «A Dynamic Mode Decomposition Framework for Global Power System Oscillation Analysis,» *IEEE Transactions on Power Systems*, vol. 30, n.º 6, págs. 2902-2912, 2015.
- [14] C. M. C. Arvizu y A. R. Messina, «Dimensionality Reduction in Transient Simulations: A Diffusion Maps Approach,» *IEEE Transactions on Power Delivery*, vol. 31, n.º 5, págs. 2379-2389, 2016.
- [15] X. Li, H. Cui, T. Jiang, Y. Xu, H. Jia y F. Li, «Multichannel continuous wavelet transform approach to estimate electromechanical oscillation modes, mode shapes and coherent groups from synchrophasors in bulk power grids,» *International Journal of Electrical Power and Energy Systems*, vol. 96, págs. 222-237, 2018.
- [16] R. Schumacher, G. H. C. Oliveira y R. Kuiava, «A multi-signal instrumental variable vector fitting method for estimating inter-area electromechanical modes of power systems,» *International Journal of Electrical Power and Energy Systems*, vol. 111, págs. 1-13, 2019.
- [17] E. S. Bañuelos-Cabral et al., «Spectral fitting approach to estimate electromechanical oscillation modes and mode shapes by using vector fitting,» *Electric Power Systems Research*, vol. 176, pág. 105 958, 2019.
- [18] A. Zamora-Mendez, R. D. R. de Luna, J. A. de la O Serna, J. H. Chow y M. R. A. Paternina, «Electromechanical Modes Identification Based on an Iterative Eigenvalue Decomposition of the Hankel Matrix,» *IEEE Transactions on Power Systems*, vol. 39, n.º 2, págs. 4000-4012, 2024.
- [19] R. D. Rodriguez-Soto, E. Barocio, F. Gonzalez-Longatt, F. R. S. Sevilla y P. Korba, «Robust Three-Stage Dynamic Mode Decomposition for Analysis of Power System Oscillations,» *IEEE Transactions on Power Systems*, vol. 39, n.º 2, págs. 4000-4012, 2024.
- [20] L. Wang, B. Wang, H. Gao, D. Yang, S. Xia y T. T. Lie, «Synchronized Data-Based Identification of Electromechanical Oscillation Modes Using Improved FastICA Considering Measurement Noise,» *IEEE Transactions on Instrumentation and Measurement*, vol. 74, pág. 3 003 413, 2025.
- [21] D. Tufts y R. Kumaresan, «Estimation of frequencies of multiple sinusoids: Making linear prediction perform like maximum likelihood,» *Proceedings of the IEEE*, vol. 70, n.º 9, págs. 975-989, 1982. DOI: 10.1109/PROC.1982.12428
- [22] M. A. Moghdam, R. Noroozian y S. Jalilzadeh, «Improving the accuracy and the estimation time of inter-area modes in power system based on Tufts-Kumaresan algorithm,» *International Journal of Modelling and Simulation*, vol. 44, n.º 3, págs. 126-135, 2024. DOI: 10.1080/02286203.2022.2161443

CAPITULO 2

MARCO TEÓRICO

RESUMEN

Las oscilaciones electromecánicas de baja frecuencia limitan la capacidad de transferencia de los sistemas eléctricos interconectados y, cuando están pobremente amortiguadas, pueden desencadenar apagones de gran escala. Su diagnóstico tradicional mediante análisis de eigenvalores exige un modelo preciso y parámetros actualizados, difíciles de mantener en redes reales. Extraer las propiedades modales — modos dominantes, formas modales, factores de participación y grupos coherentes — directamente de mediciones sincrofásicas, sin un modelo del sistema y con robustez frente al ruido es un problema abierto. Se propone un algoritmo de identificación que combine la predicción lineal multicanal de Tufts–Kumaresan, basada en el truncamiento de la descomposición en valores singulares permite estimar los parámetros modales con exactitud comparable al análisis de eigenvalores y mayor robustez al ruido que los métodos basados en datos existentes. El objetivo es establecer el marco teórico que fundamenta esa cadena, deduciendo el modelo de señal desde la física del generador síncrono y rigORIZANDO cada etapa de estimación. El capítulo articula una estructura teórica invertible que (i) deriva el modelo de exponenciales amortiguadas como consecuencia de la respuesta libre del sistema y no como postulado; (ii) sustenta el truncamiento de la SVD como filtro óptimo y la selección de orden por umbral duro óptimo; (iii) conecta las cantidades medibles con los eigenvectores del modelo de estados; y (iv) formaliza la identificación de grupos coherentes por coseno director y agrupamiento espectral. El marco se valida contra la literatura de identificación modal basada en mediciones sobre el sistema de prueba de 16 generadores y 68 buses.

2.1 INTRODUCCIÓN DEL CAPÍTULO

Este capítulo construye, de manera deductiva, el puente entre la física de las oscilaciones electromecánicas y los algoritmos de identificación modal basados en mediciones sincrofásicas que sustentan esta tesis. La exposición sigue una cadena de implicaciones:

se parte de las ecuaciones de oscilación del generador síncrono bajo el modelo clásico [1], se linealiza alrededor del punto de operación para obtener el modelo de estados cuyo espectro define los modos electromecánicos, y se demuestra — mediante la transformación modal y la respuesta libre del sistema — que toda señal registrada por una unidad de medición fasorial en régimen de *ring-down* obedece un modelo de suma de exponenciales complejas amortiguadas. Esta derivación convierte el modelo de señal en consecuencia de la física del sistema, y no en postulado, y delimita su dominio de validez: la banda electromecánica (0,1–3 Hz) observada con tasas de reporte PMU de 30 Hz o superiores [2].

Sobre esa base se desarrolla la maquinaria de estimación: la formulación discreta y su mapeo al plano z ; la predicción lineal hacia atrás multicanal de Tufts–Kumaresan y su mecanismo de separación señal–ruido [3]; el truncamiento de la SVD como filtro óptimo de Eckart–Young–Mirsky con selección de orden por energía y por umbral duro óptimo [4], [5]; la estimación de amplitudes mediante sistemas de Vandermonde estables; y el refinamiento por proyección variable [6]. La parte final traduce los parámetros en patrones dinámicos interpretables: formas modales, índices de participación y grupos coherentes [7], [8], [9]. Se incluye, además, el diseño de los estudios experimentales que validan la selección del orden del predictor L , la del orden del modelo M y las formulaciones de optimización con restricciones de subespacio.

2.1.1 DINÁMICA DE OSCILACIONES ELECTROMECAÑICAS

ECUACIONES DE SWING DEL GENERADOR SÍNCRONO

La dinámica de cada generador i en un sistema de n_g máquinas ($i = 1, \dots, n_g$) se describe mediante las **ecuaciones de swing**:

$$\dot{\delta}_i = \omega_i - \omega_s \quad (2.1)$$

$$\dot{\omega}_i = \frac{\omega_s}{2H_i} \left(P_{m,i} - P_{e,i}(\delta) - D_i(\omega_i - \omega_s) \right) \quad (2.2)$$

Las ecuaciones (2.1)–(2.2) corresponden al **modelo clásico** del generador síncrono [1]: la máquina se representa como una fuente de voltaje interna de magnitud constante E'_i detrás de la reactancia transitoria $x'_{d,i}$, con potencia mecánica $P_{m,i}$ constante en la ventana de análisis y con todos los efectos de amortiguamiento (devanados amortiguadores, cargas sensibles a la frecuencia, etc.) agregados en el coeficiente D_i . Este nivel de modelado es suficiente para caracterizar la dinámica electromecánica de interés, pues los modos de oscilación de nuestro interés entre rotores quedan determinados por el intercambio de energía cinética y potencia sincronizante entre máquinas [1], [2].

Parámetros (todas las potencias en por unidad sobre una base común S_{base}):

- δ_i : ángulo del rotor respecto a la referencia síncrona (rad);
- ω_i : velocidad angular del rotor (rad/s);
- H_i : constante de inercia, $H_i = \frac{1}{2} J_i \omega_s^2 / S_{\text{base}}$ (s);
- D_i : coeficiente de amortiguamiento (p.u. de par por p.u. de desviación de velocidad, adimensional);
- $P_{m,i}$: potencia mecánica de entrada (p.u.);
- $P_{e,i}(\delta)$: potencia eléctrica entregada — función no lineal de los ángulos de rotor $\delta = [\delta_1, \dots, \delta_{n_g}]^\top$ a través de la red a nodos de generación (p.u.);
- $\omega_s = 2\pi f_s$: velocidad síncrona de referencia (rad/s).

LINEALIZACIÓN ALREDEDOR DEL PUNTO DE OPERACIÓN

Para analizar la estabilidad de pequeña señal, se linealiza el sistema alrededor del punto de equilibrio (δ^0, ω^0) ; en régimen permanente se cumple $(\dot{\delta}_i = 0, \dot{\omega}_i = 0)$:

$$P_{m,i} = P_{e,i}(\delta^0), \quad \omega_i^0 = \omega_s \quad (2.3)$$

Se definen las variables de estado de perturbación (desviaciones):

$$\Delta\delta = \delta - \delta^0, \quad \Delta\omega = \omega - \omega^0 \quad (2.4)$$

Linealizando la primera ecuación de oscilación:

$$\Delta\dot{\delta} = \Delta\omega \quad (2.5)$$

Expandiendo la serie de Taylor de primer orden de $P_{e,i}(\delta)$ alrededor de δ^0 y usando la condición de equilibrio se linealiza la segunda ecuación de oscilación:

$$\Delta\dot{\omega}_i = \frac{\omega_s}{2H_i} \left(- \sum_{j=1}^{n_g} \frac{\partial P_{e,i}}{\partial \delta_j} \Big|_{\delta^0} \Delta\delta_j - D_i \Delta\omega_i \right) \quad (2.6)$$

Las derivadas parciales evaluadas en el punto de operación definen los **coeficientes de potencia sincronizante** [1]:

$$K_{ij} = \frac{\partial P_{e,i}}{\partial \delta_j} \Big|_{\delta^0}, \quad i, j = 1, \dots, n_g, \quad (2.7)$$

que representan el acoplamiento entre las máquinas i y j a través de la red y representa el cambio en la potencia eléctrica para un cambio en el punto de equilibr. Agrupando las

desviaciones en el vector de estados $\Delta \mathbf{x} = [\Delta \delta^\top \ \Delta \omega^\top]^\top \in \mathbb{R}^{2n_g}$, el sistema linealizado adquiere la forma canónica de espacio de estados en lazo abierto (movimiento libre):

$$\Delta \dot{\mathbf{x}} = \mathbf{A} \Delta \mathbf{x}, \quad \mathbf{A} = \begin{bmatrix} \mathbf{0} & \mathbf{I}_{n_g} \\ -\omega_s \mathbf{M}^{-1} \mathbf{K} & -\omega_s \mathbf{M}^{-1} \mathbf{D} \end{bmatrix} \in \mathbb{R}^{2n_g \times 2n_g}, \quad (2.8)$$

donde $\mathbf{M} = \text{diag}(2H_1, \dots, 2H_{n_g})$, $\mathbf{D} = \text{diag}(D_1, \dots, D_{n_g})$ y $\mathbf{K} = [K_{ij}] \in \mathbb{R}^{n_g \times n_g}$ es la matriz de coeficientes de potencia sincronizante. La estabilidad de pequeña señal del punto de operación queda gobernada por los eigenvalores de $\mathbf{A}$, raíces de la ecuación característica $\det(s\mathbf{I} - \mathbf{A}) = 0$ [1].

SOLUCIÓN MODAL: DEL ESPACIO DE ESTADOS A LA SUMA DE EXPONENCIALES AMORTIGUADAS

Sea $\{\lambda_k\}_{k=1}^{2n_g}$ el espectro de $\mathbf{A}$, con eigenvectores derechos ϕ_k e izquierdos ψ_k que satisfacen

$$\mathbf{A}\phi_k = \lambda_k \phi_k, \quad \psi_k^\top \mathbf{A} = \lambda_k \psi_k^\top, \quad \psi_j^\top \phi_k = \delta_{jk}. \quad (2.9)$$

La transformación $\Delta \mathbf{x} = \Phi \mathbf{z}$, con $\Phi = [\phi_1 \cdots \phi_{2n_g}]$, desacopla (2.8) en $2n_g$ ecuaciones escalares $\dot{z}_k = \lambda_k z_k$, de modo que la respuesta libre ante una perturbación inicial $\Delta \mathbf{x}(0)$ es [1]

$$\Delta \mathbf{x}(t) = \sum_{k=1}^{2n_g} \phi_k \underbrace{(\psi_k^\top \Delta \mathbf{x}(0))}_{c_k} e^{\lambda_k t}. \quad (2.10)$$

Dado que $\mathbf{A}$ es real, los eigenvalores oscilatorios aparecen en pares complejos conjugados $\lambda_k = \sigma_k \pm j\omega_k$; cada par constituye un **modo electromecánico de oscilación** con frecuencia $f_k = \omega_k/2\pi$ y razón de amortiguamiento

$$\zeta_k = \frac{-\sigma_k}{\sqrt{\sigma_k^2 + \omega_k^2}}. \quad (2.11)$$

Cualquier señal medida $x_i(t)$ que sea combinación lineal de los estados — es el caso de desviaciones de velocidad de rotor, frecuencia de bus, potencia activa o ángulos de tensión registrados por un PMU, expresables como $x_i = \mathbf{c}_i^\top \Delta \mathbf{x}$ — tiene la misma estructura espectral:

$$x_i(t) = \sum_{k=1}^{2n_g} \underbrace{(\mathbf{c}_i^\top \phi_k) c_k}_{a_{i,k}} e^{\lambda_k t}, \quad (2.12)$$

lo que justifica, desde la física del sistema, el modelo de suma de exponenciales amortiguadas que adoptan los algoritmos de identificación modal de las secciones siguientes. La amplitud compleja $a_{i,k}$ acopla la *observabilidad* del modo k en el canal i (a través de $\mathbf{c}_i^\top \phi_k$, es decir,

de la forma modal) con la *excitación* del modo por la perturbación (a través de c_k) [1].

MODOS ELECTROMECAÑICOS Y SU OBSERVACIÓN MEDIANTE SINCROFASORES (WAMS)

Los modos oscilatorios de (2.10) se clasifican según su extensión geográfica y banda de frecuencia [1], [2]: **modos locales** (una planta contra el resto del sistema, aproximadamente 1–3 Hz) y **modos interárea** (grupos coherentes de generadores oscilando entre sí, por debajo de 1 Hz, típicamente 0,25–1 Hz). Los modos interárea, de bajo amortiguamiento ($\zeta_k < 3\%$) y difícil diagnóstico, limitan las transferencias de potencia y constituyen el objeto principal de la identificación modal [2].

Las unidades de medición fasorial (PMU) de un sistema de monitoreo de área amplia (WAMS) entregan fasores de tensión y corriente, frecuencia y potencias sincronizados vía GPS, con tasas de reporte de 30 a 120 muestras por segundo [2]. Puesto que la banda electromecánica completa se encuentra por debajo de 3 Hz, una tasa de reporte $F_s \geq 30$ Hz satisface holgadamente el criterio de Nyquist ($F_s > 2f_k$) y dota a las señales sincrofatorias de la resolución temporal necesaria para estimar tanto ω_k como σ_k [2]. En contraste, los sistemas SCADA convencionales, con periodos de muestreo del orden de segundos, no resuelven esta dinámica.

Tras una gran perturbación, la respuesta inmediata del sistema es fuertemente no lineal; sin embargo, una vez que las trayectorias se aproximan al nuevo punto de equilibrio, las oscilaciones decrecientes registradas por los PMU — el régimen de **ring-down** — se modelan con precisión como la respuesta libre de un sistema lineal no forzado [2]. Es en este régimen donde el modelo (2.12) es válido y donde operan los algoritmos de predicción lineal desarrollados a continuación.

2.2 FORMULACIÓN DISCRETA Y PREDICCIÓN LINEAL

2.2.1 DEL TIEMPO CONTINUO AL DOMINIO MUESTREADO

Muestreando cada señal $x_i(t)$ de (2.12) con periodo $\Delta t = 1/F_s$, definimos $x_i[n] = x_i(n\Delta t)$ para $n = 0, 1, \dots, N-1$. El modelo continuo de suma de exponenciales amortiguadas se transforma exactamente en

$$x_i[n] = \sum_{k=1}^M a_{i,k} z_k^n, \quad z_k = e^{\lambda_k \Delta t} = e^{(\sigma_k + j\omega_k) \Delta t}, \quad (2.13)$$

donde $M \leq 2n_g$ es el número de modos efectivamente observables en la ventana de datos. Puesto que las señales medidas son reales, los polos z_k y las amplitudes $a_{i,k}$ aparecen en pares complejos conjugados, por lo que M es par para modos puramente oscilatorios. Los polos en tiempo discreto contienen toda la información modal:

$$z_k = e^{(\sigma_k + j\omega_k)\Delta t}, \quad (2.14)$$

$$\lambda_k = \sigma_k + j\omega_k = \frac{\ln z_k}{\Delta t}, \quad |\omega_k| \Delta t < \pi. \quad (2.15)$$

La condición $|\omega_k| \Delta t < \pi$ es el criterio de Nyquist que garantiza la unicidad de la rama principal del logaritmo complejo en (2.15); las tasas de reporte PMU ($F_s \geq 30$ Hz) la satisfacen con amplio margen para la banda electromecánica ($f_k \leq 3$ Hz) [2]. A partir de las raíces z_k del polinomio de predicción se recuperan el amortiguamiento $\sigma_k = \text{Re}(\ln z_k)/\Delta t$, la frecuencia $\omega_k = \text{Im}(\ln z_k)/\Delta t$ y la razón de amortiguamiento ζ_k de (2.11).

2.3 ALGORITMO TUFTS-KUMARESAN MULTIVARIABLE (MULTI-TK)

2.3.1 MODELO DE SEÑAL Y PREDICCIÓN LINEAL HACIA ATRÁS

Para P señales medidas $\{x_i[n]\}_{i=1}^P$, cada una de N muestras ($n = 0, \dots, N-1$), el modelo de señal con ruido de medición $w_i[n]$ es

$$x_i[n] = \sum_{k=1}^M a_{i,k} z_k^n + w_i[n], \quad z_k = e^{(\sigma_k + j\omega_k)\Delta t}.$$

Se elige un orden de predictor L tal que $M \leq L \leq N - M$. Para cada canal i se plantea el problema de **predicción lineal hacia atrás**:

$$\mathbf{A}_i \mathbf{b} = -\mathbf{h}_i, \quad (2.16)$$

donde $\mathbf{b} = [b(1), b(2), \dots, b(L)]^\top$ es el vector de coeficientes del polinomio característico.

La elección de la predicción *hacia atrás* sobre datos conjugados no es accidental: constituye el mecanismo de discriminación señal–ruido del método de Tufts–Kumaresan [3]. Al elegir un orden sobredimensionado $L > M$, el polinomio característico

$$B(z) = 1 + \sum_{\ell=1}^L b(\ell) z^{-\ell} \quad (2.17)$$

posee L raíces, de las cuales sólo M corresponden a modos físicos. En la formulación hacia atrás, las raíces de señal se ubican en los recíprocos conjugados de los polos, $1/z_k^*$: para modos amortiguados ($|z_k| < 1$) éstas quedan **fuera** del círculo unitario, mientras que las $L - M$ raíces extrañas inducidas por el ruido tienden a permanecer **dentro** de él [3]. Esta

separación geométrica en el plano z permite identificar los modos físicos sin ambigüedad, propiedad de la que carece la predicción hacia adelante del método de Prony clásico [2], [10], cuya estructura Hankel es por lo demás análoga a (2.18).

La matriz de Hankel conjugada para la i -ésima señal (el asterisco denota conjugación compleja) se construye como:

$$\mathbf{A}_i = \begin{bmatrix} x_i^*(1) & x_i^*(2) & \cdots & x_i^*(L) \\ x_i^*(2) & x_i^*(3) & \cdots & x_i^*(L+1) \\ \vdots & \vdots & \ddots & \vdots \\ x_i^*(N-L) & x_i^*(N-L+1) & \cdots & x_i^*(N-1) \end{bmatrix} \in \mathbb{C}^{(N-L) \times L}, \quad (2.18)$$

y el vector objetivo asociado es

$$\mathbf{h}_i = \begin{bmatrix} x_i^*(0) \\ x_i^*(1) \\ \vdots \\ x_i^*(N-L-1) \end{bmatrix} \in \mathbb{C}^{N-L}. \quad (2.19)$$

2.3.2 SISTEMA GLOBAL MULTICANAL

Se apilan verticalmente las matrices y los vectores de todos los canales:

$$\mathbf{A}_{\text{multi}} = \begin{bmatrix} \mathbf{A}_1 \\ \mathbf{A}_2 \\ \vdots \\ \mathbf{A}_P \end{bmatrix} \in \mathbb{C}^{P(N-L) \times L}, \quad \mathbf{h}_{\text{multi}} = \begin{bmatrix} \mathbf{h}_1 \\ \mathbf{h}_2 \\ \vdots \\ \mathbf{h}_P \end{bmatrix} \in \mathbb{C}^{P(N-L)}. \quad (2.20)$$

El sistema completo de predicción lineal es:

$$\boxed{\mathbf{A}_{\text{multi}} \mathbf{b} = -\mathbf{h}_{\text{multi}}}. \quad (2.21)$$

2.3.3 DESCOMPOSICIÓN SVD Y SELECCIÓN DEL ORDEN DEL MODELO

Se aplica la **descomposición en valores singulares** a $\mathbf{A}_{\text{multi}}$:

$$\mathbf{A}_{\text{multi}} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^H, \quad (2.22)$$

con $\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ (en esta sección, σ_k denota los valores singulares de $\mathbf{A}_{\text{multi}}$, no el amortiguamiento modal).

La optimalidad del truncamiento de la SVD está garantizada por el teorema de Eckart–Young–Mirsky [4]: la mejor aproximación de rango M a una matriz, en el sentido de

mínimos cuadrados, es precisamente su SVD truncada.

Sea $\mathbf{A}_{\text{multi}} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^H$. Entonces

$$\mathbf{U}_s \mathbf{\Sigma}_s \mathbf{V}_s^H = \arg \min_{\text{rank}(\mathbf{B}) \leq M} \|\mathbf{A}_{\text{multi}} - \mathbf{B}\|_F, \quad (2.23)$$

y el error de aproximación queda exactamente cuantificado por la energía de los valores singulares descartados:

$$\|\mathbf{A}_{\text{multi}} - \mathbf{U}_s \mathbf{\Sigma}_s \mathbf{V}_s^H\|_F^2 = \sum_{k=M+1}^r \sigma_k^2. \quad (2.24)$$

Bajo el modelo aditivo $\mathbf{A}_{\text{multi}} = \mathbf{A}_{\text{seal}} + \mathbf{A}_{\text{ruido}}$, donde $\text{rank}(\mathbf{A}_{\text{seal}}) = M$ por construcción del modelo (2.13), los primeros M valores singulares capturan el subespacio de señal y los restantes la contribución del ruido de medición; el truncamiento de rango M actúa entonces como un filtro óptimo en el sentido de (2.23) [3], [4].

El número de modos M se selecciona mediante el criterio de **energía acumulada**:

$$E_{s,M} = \frac{\sum_{k=1}^M \sigma_k^2}{\sum_{k=1}^r \sigma_k^2} \geq E_0, \quad (2.25)$$

donde típicamente $E_0 = 97\%$ (o $99,9\%$ según el nivel de ruido).

2.3.4 TRUNCAMIENTO DE LA SVD Y SOLUCIÓN DEL SISTEMA

Se retiene el subespacio de señal de rango M :

$$\mathbf{A}_{\text{multi}} \approx \mathbf{U}_s \mathbf{\Sigma}_s \mathbf{V}_s^H, \quad \mathbf{U}_s \in \mathbb{C}^{P(N-L) \times M}, \quad \mathbf{\Sigma}_s \in \mathbb{R}^{M \times M}, \quad \mathbf{V}_s \in \mathbb{C}^{L \times M}. \quad (2.26)$$

La solución regularizada del sistema es:

$$\boxed{\mathbf{b} = -\mathbf{V}_s \mathbf{\Sigma}_s^{-1} \mathbf{U}_s^H \mathbf{h}_{\text{multi}}}. \quad (2.27)$$

La ecuación (2.27) es la solución de mínimos cuadrados mediante la **pseudoinversa de Moore–Penrose truncada** [4]:

$$\mathbf{b} = -\mathbf{A}_{\text{multi}}^{+(M)} \mathbf{h}_{\text{multi}}, \quad \mathbf{A}_{\text{multi}}^{+(M)} = \mathbf{V}_s \mathbf{\Sigma}_s^{-1} \mathbf{U}_s^H. \quad (2.28)$$

Esta solución posee una doble optimalidad [4]: minimiza el residuo $\|\mathbf{A}_{\text{multi}} \mathbf{b} + \mathbf{h}_{\text{multi}}\|_2$ restringido al subespacio de señal de rango M y, entre todas las soluciones que lo logran, es

la de mínima norma $\|\mathbf{b}\|_2$. El truncamiento cumple además una función de regularización numérica: en la pseudoinversa completa, los valores singulares pequeños asociados al ruido aparecen invertidos (σ_k^{-1} grande) y amplifican catastróficamente la componente de ruido de $\mathbf{h}_{\text{multi}}$; al retener sólo Σ_s , dicha amplificación se elimina y la varianza del estimador de $\mathbf{b}$ se reduce drásticamente [3], [4]. Para la longitud del predictor se recomienda $L \approx \frac{3N}{4}$, valor que maximiza el desempeño del estimador en presencia de ruido [3].

2.4 PATRONES DINÁMICOS: FORMAS MODALES Y FACTORES DE PARTICIPACIÓN

2.4.1 ESTIMACIÓN DE AMPLITUDES COMPLEJAS

Conocidos los polos $\{z_k\}_{k=1}^M$, para cada señal i se resuelve:

$$\underbrace{\begin{bmatrix} z_1^0 & z_2^0 & \cdots & z_M^0 \\ z_1^1 & z_2^1 & \cdots & z_M^1 \\ \vdots & & \ddots & \vdots \\ z_1^{N-1} & z_2^{N-1} & \cdots & z_M^{N-1} \end{bmatrix}}_{\Psi} \begin{bmatrix} a_{i,1} \\ a_{i,2} \\ \vdots \\ a_{i,M} \end{bmatrix} = \mathbf{x}_i \quad (2.29)$$

Mediante mínimos cuadrados:

$$\mathbf{a}_i = \Psi^+ \mathbf{x}_i = (\Psi^H \Psi)^{-1} \Psi^H \mathbf{x}_i \quad (2.30)$$

La matriz $\Psi \in \mathbb{C}^{N \times M}$ es una matriz de **Vandermonde** construida sobre los polos estimados. En la práctica, la solución vía ecuaciones normales $(\Psi^H \Psi)^{-1} \Psi^H$ debe evitarse: cuando el sistema presenta modos de frecuencias cercanas — situación típica de los modos interárea — los nodos z_k se aglomeran y Ψ se vuelve mal condicionada, y el producto $\Psi^H \Psi$ eleva al cuadrado su número de condición, $\kappa(\Psi^H \Psi) = \kappa(\Psi)^2$. La alternativa numéricamente estable es la pseudoinversa calculada mediante la SVD de Ψ [4]:

$$\mathbf{a}_i = \mathbf{V}_\Psi \Sigma_\Psi^{-1} \mathbf{U}_\Psi^H \mathbf{x}_i, \quad \Psi = \mathbf{U}_\Psi \Sigma_\Psi \mathbf{V}_\Psi^H. \quad (2.31)$$

2.4.2 DISCRIMINACIÓN DE MODOS DOMINANTES POR ENERGÍA MODAL

Los estimadores con orden sobredimensionado (Multi-TK con $L > M$, VarPro con modos triviales adicionales para absorber ruido) entregan un conjunto de modos en el que los modos físicos dominantes están mezclados con modos triviales. Para separarlos, además del criterio sobre valores singulares (2.25), se emplea el criterio de **energía modal** sobre las amplitudes estimadas [7]: la energía del modo k se define a partir de las amplitudes

complejas de todos los canales,

$$E_k = \sum_{i=1}^P |a_{i,k}|^2 = \|\mathbf{s}_k\|_2^2, \quad (2.32)$$

y los modos se ordenan por energía decreciente. El peso de energía acumulada

$$E_{s,k} = \frac{\sum_{i=1}^k E_i}{\sum_{i=1}^M E_i} \times 100 \% \quad (2.33)$$

determina los k primeros modos como dominantes cuando $E_{s,k} \geq E_0$, con $E_0 = 85 \%$ como valor validado empíricamente frente al análisis de eigenvalores y a la densidad espectral de potencia en el sistema de prueba de 16 generadores y 68 buses [7]. A diferencia de (2.25), que opera sobre el subespacio de la matriz de datos *antes* de estimar los polos, el criterio (2.33) opera sobre la contribución de cada modo ya estimado a la reconstrucción de las señales, por lo que ambos criterios son complementarios: el primero fija el orden del modelo M y el segundo jerarquiza los modos físicos dentro de ese orden.

2.4.3 FORMA MODAL (MODE SHAPE)

La **forma modal** del modo k describe la distribución espacial:

$$\mathbf{s}_k = \begin{bmatrix} a_{1,k} \\ a_{2,k} \\ \vdots \\ a_{P,k} \end{bmatrix} = \begin{bmatrix} |a_{1,k}| e^{j\phi_{1,k}} \\ |a_{2,k}| e^{j\phi_{2,k}} \\ \vdots \\ |a_{P,k}| e^{j\phi_{P,k}} \end{bmatrix} \quad (2.34)$$

La magnitud $|\mathbf{s}_k|$ indica observabilidad; la fase $\angle \mathbf{s}_k$ revela relaciones entre señales. Para comparar formas modales entre modos o entre métodos, $\mathbf{s}_k$ se normaliza a norma unitaria, $\hat{\mathbf{s}}_k = \mathbf{s}_k / \|\mathbf{s}_k\|_2$, o respecto a su componente de mayor magnitud, convención empleada en la literatura de identificación basada en mediciones [7], [9].

La forma modal empírica $\mathbf{s}_k$ tiene una interpretación exacta en términos del modelo de estados (2.8): por (2.12), $a_{i,k} = (\mathbf{c}_i^\top \boldsymbol{\phi}_k) c_k$, de modo que

$$\mathbf{s}_k = c_k \begin{bmatrix} \mathbf{c}_1^\top \boldsymbol{\phi}_k \\ \vdots \\ \mathbf{c}_P^\top \boldsymbol{\phi}_k \end{bmatrix}, \quad (2.35)$$

es decir, $\mathbf{s}_k$ es la proyección del **eigenvector derecho** $\boldsymbol{\phi}_k$ sobre los canales medidos,

escalada por el factor de excitación c_k , común a todos los canales. Dado que c_k es un escalar, las magnitudes *relativas* y las fases *relativas* entre canales de $\mathbf{s}_k$ coinciden con las del eigenvector derecho, que es precisamente la forma modal del análisis de pequeña señal [1]. En particular, los canales en contrafase ($\Delta\phi \approx 180^\circ$) identifican los grupos coherentes de generadores que oscilan uno contra otro en un modo interárea.

2.4.4 FACTOR DE PARTICIPACIÓN

Para el modo k , la participación normalizada de la señal i es:

$$\hat{p}_{ik} = \frac{|a_{i,k}|}{\sum_{j=1}^P |a_{j,k}|} \quad (2.36)$$

Debe distinguirse $\hat{p}_{ik}$ del **factor de participación** del análisis de pequeña señal, definido como el producto de los elementos de los eigenvectores derecho e izquierdo,

$$p_{ki} = \phi_{ki} \psi_{ik}, \quad (2.37)$$

que mide la participación neta del estado k en el modo i combinando actividad (eigenvector derecho) y controlabilidad de la condición inicial (eigenvector izquierdo), y cuya evaluación exige el conocimiento explícito de la matriz $\mathbf{A}$ [1]. El índice $\hat{p}_{ik}$ aquí propuesto es, en cambio, una medida *empírica de observabilidad relativa* del modo k en el canal i , calculable exclusivamente a partir de mediciones sincrofasoriales sin requerir un modelo del sistema. Ambas nociones coinciden en su uso práctico: jerarquizar las señales (y por ende las máquinas o áreas) dominantes en cada modo e identificar los grupos coherentes de generadores, lo que habilita la localización de los canales óptimos para monitoreo y control de oscilaciones [2]. Esta distinción está respaldada por la literatura de identificación basada en mediciones: los métodos que estiman explícitamente una realización de estado (p. ej. ERA) recuperan el factor de participación formal a partir de los eigenvectores derecho e izquierdo de la matriz de estados realizada [9], mientras que los métodos de ajuste de amplitudes (OptVarPro, Prony multicanal, Multi-TK) construyen índices de participación a partir de las magnitudes $|a_{i,k}|$ [7]. En ambos enfoques se ha verificado, sobre el sistema de prueba de 16 generadores y 68 buses, que los generadores con mayor índice empírico coinciden con los de mayor factor de participación obtenido por análisis de eigenvalores, aun cuando los valores numéricos difieren [7], [9].

2.4.5 IDENTIFICACIÓN DE GRUPOS COHERENTES: COSENO DIRECTOR Y AGRUPAMIENTO ESPECTRAL

La forma modal de un solo modo separa a los generadores en, a lo sumo, dos grupos en contrafase; la partición del sistema en grupos coherentes bajo la acción conjunta de *múltiples* modos dominantes requiere una medida de similitud entre generadores construida sobre el conjunto completo de formas modales [7], [8]. Sea $\mathbf{r}_i = [a_{i,1}, a_{i,2}, \dots, a_{i,M}] \in \mathbb{C}^{1 \times M}$ la fila de amplitudes complejas (residuos) del generador i sobre los M modos dominantes, normalizada a norma unitaria, $\hat{\mathbf{r}}_i = \mathbf{r}_i / \|\mathbf{r}_i\|_2$. El **coseno director** entre los generadores i y j se define como la parte real del producto interno complejo normalizado:

$$r_{ij} = \text{Re}(\hat{\mathbf{r}}_i \hat{\mathbf{r}}_j^H) \in [-1, 1]. \quad (2.38)$$

Dos generadores completamente coherentes (misma respuesta modal, fase relativa nula) tienen $r_{ij} = 1$; dos generadores en contrafase perfecta tienen $r_{ij} = -1$ [8], [9]. Es esencial conservar el signo en (2.38): tomar la magnitud $|\hat{\mathbf{r}}_i \hat{\mathbf{r}}_j^H|$ colapsa el rango a $[0, 1]$ y asigna similitud máxima a generadores en oposición de fase, que por definición pertenecen a grupos coherentes distintos.

REFERENCIAS

- [1] P. Kundur, *Power System Stability and Control* (EPRI Power System Engineering Series). New York: McGraw-Hill, 1994.
- [2] P. W. Sauer, M. A. Pai y J. H. Chow, *Power System Dynamics and Stability: With Synchrophasor Measurement and Power System Toolbox*, 2.^a ed. Hoboken, NJ: Wiley-IEEE Press, 2017.
- [3] D. W. Tufts y R. Kumaresan, «Estimation of Frequencies of Multiple Sinusoids: Making Linear Prediction Perform Like Maximum Likelihood,» *Proceedings of the IEEE*, vol. 70, n.º 9, págs. 975-989, 1982. DOI: 10.1109/PROC.1982.12428
- [4] S. L. Brunton y J. N. Kutz, *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*, 2.^a ed. Cambridge: Cambridge University Press, 2022.
- [5] M. Gavish y D. L. Donoho, «The Optimal Hard Threshold for Singular Values is $4/\sqrt{3}$,» *IEEE Transactions on Information Theory*, vol. 60, n.º 8, págs. 5040-5053, 2014. DOI: 10.1109/TIT.2014.2323359
- [6] T. Askham y J. N. Kutz, «Variable Projection Methods for an Optimized Dynamic Mode Decomposition,» *SIAM Journal on Applied Dynamical Systems*, vol. 17, n.º 1, págs. 380-416, 2018. DOI: 10.1137/M1124176
- [7] T. Jiang, X. Kou, G. Liu y H. Yuan, «Synergistic Data Analytics for Electromechanical Oscillation in Electric Power Systems,» *International Journal of Electrical Power and Energy Systems*, vol. 135, pág. 107 610, 2022. DOI: 10.1016/j.ijepes.2021.107610
- [8] X. Li, H. Cui, T. Jiang, Y. Xu, H. Jia y F. Li, «Multichannel Continuous Wavelet Transform Approach to Estimate Electromechanical Oscillation Modes, Mode Shapes and Coherent Groups from Synchrophasors in Bulk Power Grids,» *International Journal of Electrical Power and Energy Systems*, vol. 96, págs. 222-237, 2018. DOI: 10.1016/j.ijepes.2017.09.043
- [9] X. Li et al., «An Eigensystem Realization Algorithm Based Data-Driven Approach for Extracting Electromechanical Oscillation Dynamic Patterns from Synchrophasor Measurements in Bulk Power Grids,» *International Journal of Electrical Power and Energy Systems*, vol. 116, pág. 105 549, 2020. DOI: 10.1016/j.ijepes.2019.105549
- [10] J. F. Hauer, C. J. Demeure y L. L. Scharf, «Initial Results in Prony Analysis of Power System Response Signals,» *IEEE Transactions on Power Systems*, vol. 5, n.º 1, págs. 80-89, 1990. DOI: 10.1109/59.49090

CAPITULO 3

RESULTADOS

