

UNIVERSIDAD DE GUADALAJARA,
CENTRO UNIVERSITARIO DE CIENCIAS EXACTAS E INGENIERÍAS
DIVISIÓN DE INGENIERÍAS



**Identificación de modos de oscilación electromecánicos mediante
una técnica de Tufts-Kumaresan multivariable**

TESIS QUE PARA OBTENER EL GRADO DE
Maestro en Ciencias en Ingeniería Eléctrica

PRESENTA

Ing. Glader David Hernández Reyes

DIRECTOR DE TESIS

Dr. José de Jesús Nuño Ayon

Guadalajara, Jalisco, Septiembre 2026

DEDICATORIA

A quienes formaron mi caracter y me enseñaron a ser quien soy.

AGRADECIMIENTOS

A mi madre Antonia, quien me dio vida y me ha cuidado durante mi efímera existencia. La persona que me enseñó la importancia de trabajar; que el esfuerzo constante junto con disciplina rinde frutos tarde o temprano. Quien, a pesar de todas las adversidades, siempre encontró la fuerza para salir adelante, quien nunca se detuvo por no saber, a la que buscó y encontró soluciones a los problemas que la vida siempre ha conllevado. Mi razón de ser, mi ejemplo a seguir, mi madre.

A mi madre Rosario, que en paz descansa, quien me dio su amor y me demostró que uno nunca deja de aprender. Sin saber leer ni escribir, nos brindó un futuro en el cual pudimos desarrollarnos tal como ella nos enseñó, trabajando y esforzándose. Quien sin saber donde terminaríamos nos dio las posibilidades de estudiar, de poder hacer eso que ellos nunca se les permitió, gracias eternamente por las oportunidades y su eterno amor.

Mi tío Felipe, mi figura paterna, quien por muchos años, representó lo que se me negó, un padre. Quien me enseñó el respeto de existir, a ser responsable con las obligaciones del ser, a ser cuidadoso con las vivencias del mundo, a tener siempre claro nuestras metas y saber donde queremos llegar, ese rigor que con cariño me formó durante mi crecimiento.

Mis hermanos Frida Ximena, Dylan Anthony, Valeria del Rosario, quienes sin ser hijos de mi madre, con ellos compartí hogar, educación y momentos de vida. A quienes dirijo mi forma de ser. A quienes me motivan a no dejar de aprender y seguir creciendo en todos los aspectos del vivir.

ÍNDICE GENERAL

DEDICATORIA	IX
AGRADECIMIENTOS	XI
ÍNDICE GENERAL	XIII
ÍNDICE DE FIGURAS	XIV
ÍNDICE DE TABLAS	XV

CAPITULO 1

INTRODUCCIÓN	1
1.1. Antecedentes	3
1.1.1. Técnicas de análisis multivariantes	4
1.1.2. Técnicas que aproximan patrones dinámicos	5
1.1.3. Familias de algoritmos	7
1.2. Justificación	9
1.3. Objetivos	10
1.3.1. General	10
1.3.2. Específicos	10
1.4. Hipótesis	11
1.5. Metodología	11
1.6. Cronograma	11
Referencias	13

CAPITULO 2

MARCO TEÓRICO	17
2.1. Introducción del Capítulo	17
2.1.1. Dinámica de Oscilaciones Electromecánicas	18
2.2. Formulación Discreta y Predicción Lineal	21
2.2.1. Del Tiempo Continuo al Dominio Muestreado	21

2.3.	Algoritmo Tufts-Kumaresan Multivariable (Multi-TK)	22
2.3.1.	Modelo de Señal y Predicción Lineal hacia Atrás	22
2.3.2.	Sistema Multicanal	23
2.3.3.	Descomposición en Valores Singulares (SVD) y Selección del Orden del Modelo	24
2.4.	Una Aproximación a los Patrones Dinámicos	25
2.4.1.	Estimación de Amplitudes Complejas	25
2.4.2.	Discriminación de Modos Dominantes por Energía Modal	26
2.4.3.	Forma Modal (Mode Shape)	27
2.4.4.	Índices de Participación	28
2.4.5.	Identificación de Grupos Coherentes: Coseno Director y Agrupamiento Espectral	29
2.5.	Metodología propuesta	31
2.6.	Señales de prueba sintéticas	32
2.6.1.	Robustez frente al Ruido de Medición	35
2.6.2.	Maximo de Modos Cercanos Resolubles (Límite de Resolución)	36
2.6.3.	Efecto en el numero de canales	37
2.6.4.	Sensibilidad al Orden del Predictor L	37
2.6.5.	De Paramétrico a no Paramétrico: comparación de los criterios de truncamiento de la SVD	37
	Referencias	38

CAPITULO 3

RESULTADOS	41
-------------------	----

ÍNDICE DE FIGURAS

1.1. Clasificación de Articulos en funcion de los patrones dinamicos estimados	7
1.2. Clasificación de Técnicas Multivariables (WAMS)	8
2.1. Diagrama de flujo de la metodología	31
2.2. Señales de prueba sintéticas.	33
2.3. Distribución de los valores propios de las señales de prueba.	34
2.4. Plano Z de los valores propios de las señales de prueba.	35
2.5. Truncamiento de la svd mediante los metodos propuestos.	36
2.6. Errores por cada parametro estimado.	36

ÍNDICE DE TABLAS

1.1. Cronograma de actividades (Agosto 2025 - Diciembre 2026)	12
2.1. Parámetros modales del banco de señales.	32

CAPITULO 1

INTRODUCCIÓN

Desde finales del siglo XIX, Thomas A. Edison comenzó con el trabajo de electrificación, creando por primera vez, una red eléctrica de corriente continua (CC) en New York en 1882, la estación Pearl Street generaba 30 kW a 110 Volts para un total de 59 clientes. Luego, Nikola Tesla hizo publicaciones sobre las ventajas de la corriente alterna (CA), que describen motores de inducción y síncronos de dos fases. En 1891 se puso en marcha la primera red eléctrica trifásica de CA en Alemania, transmitiendo energía a 179 km a 12 kV. Para Estados Unidos en 1893 se puso la primera red eléctrica de CA en California, una red de 12 km a 2.3 kV [1]. En México, la primera red eléctrica se deriva de una fábrica de tejidos en la ciudad de León, Guanajuato en 1879, y en menos de 10 años se tenía una capacidad instalada en todo México de 937.89 kW en 60 estaciones eléctricas [2].

Con el paso de las décadas, estas pequeñas redes eléctricas fueron evolucionando gradualmente, hasta llegar a ser las grandes redes eléctricas interconectadas, incluso internacionalmente, que conocemos hoy en día. Estas grandes redes son la infraestructura más grande de la sociedad moderna. Por lo que la red eléctrica puede ser definida como el conjunto de cables y máquinas que conectan las fuentes de electricidad (las estaciones de energía) con los clientes y la infinidad de diferentes usos [3].

Usualmente estas grandes redes están fuertemente interconectadas, por lo que una falla lo suficientemente severa genera grandes problemas a lo largo de toda la red interconectada. En este contexto podemos definir la estabilidad del sistema eléctrico como la capacidad del sistema de mantener su estado de operación sin mayores desviaciones en las variables eléctricas (voltaje, frecuencia, ángulo de fase), tras haber sido sometido a una falla o perturbación en la red [4], [5], [6].

A lo largo de la historia, las vulnerabilidades de las grandes redes interconectadas se han hecho evidentes debido a los grandes apagones que han ocurrido en diferentes regiones del mundo. En Estados Unidos por ejemplo, los cortes de energía y las perturbaciones en la red eléctrica cuestan anualmente entre 75,000 y 180,000 millones de dólares [3]. Las diferentes fallas consecutivas durante los últimos 40 años ponen en evidencia la vulnerabilidad y la necesidad de comprender los fenómenos de estabilidad, para el desarrollo de controles y la

restauración de la red. Para poder diseñar estas medidas, es necesario clasificar los diferentes tipos de estabilidad, dependiendo de la naturaleza física del fenómeno de inestabilidad, el tamaño de la perturbación, los dispositivos, procesos y el tiempo involucrado. Una de las categorías recae en la estabilidad del rotor, la cual se puede definir como la capacidad de las máquinas síncronas interconectadas de mantener sincronismo entre sí después de sufrir algún disturbio [4], [5], [6].

Estas perturbaciones desbalancean el par mecánico y eléctrico de las máquinas síncronas, dando lugar a oscilaciones de baja frecuencia (LFOs) que pueden ser amortiguadas o no, dependiendo de las características del sistema. Las LFOs se pueden ver como modos (frecuencia y amortiguamiento de la oscilación) electromecánicos de oscilación, y dependiendo de su naturaleza pueden causar inestabilidad en el sistema eléctrico de potencia. Las oscilaciones electromecánicas son aquellas asociadas con la tendencia de los generadores de mantener el sincronismo cuando están interconectados [7]. Los modos se clasifican como locales (1 a 2 Hz) o inter-área (0.2 a 1 Hz), dependiendo de la ubicación de las máquinas involucradas en la oscilación. Los modos locales involucran a una o pocas máquinas en una misma área geográfica, mientras que los modos inter-área involucran a grupos de máquinas en diferentes áreas geográficas que oscilan entre sí [7].

Los grandes sistemas de potencia son multimodales, lo que quiere decir, su respuesta a una perturbación se compone de una mezcla de diferentes frecuencias oscilatorias, cada uno con su propia tasa de decaimiento. En un sistema con n máquinas síncronas, existen $n - 1$ modos de oscilación electromecánicos [7]. Por lo tanto, en sistemas con grandes interconexiones se pueden tener miles de modos oscilatorios, aunque, solo una pequeña fracción de ellos se ven implicados en la respuesta del sistema, esto hace que los sistemas de gran tamaño sean difíciles de analizar y comprender.

Los sistemas de excitación con altas ganancias de campo y respuestas rápidas, y a su vez los sistemas de velocidad de turbinas con mayor ancho de banda reducen las contribuciones de torque amortiguante de las máquinas síncronas. Los sistemas estabilizadores de potencia (PSS) son diseñados para mejorar la amortiguación de las oscilaciones, pero tienen una controlabilidad limitada sobre modos inter-área de baja frecuencia. El aumento de la transferencias de potencia a lo largo de la red y el incremento de la generación basada en energías renovables, degradan la capacidad de mantener la estabilidad oscilatoria del sistema [8].

Existen dos diferentes aproximaciones para computar los modos de oscilación, el primero basado en la linealización de las ecuaciones del sistema de potencia, y la segunda se basa en la información modal a partir de datos en el dominio del tiempo. Para grandes sistemas de potencia, con modelos detallados en cada máquina, el problema se vuelve computacionalmente muy demandante, el detectar y mitigar estos modos mediante las mediciones disponibles surge como una herramienta crucial para garantizar la estabilidad y confiabilidad [8].

La estimación de estos modos, que puede revelar características dinámicas de las oscilaciones electromecánicas, es esencial para evaluar y amortiguar la oscilación. La necesidad de un monitoreo de la dinámica del sistema es más crucial que nunca, los sistemas tradicionales de Control de Supervisión y Adquisición de Datos (por sus siglas en inglés SCADA) son insuficientes para el análisis, debido a sus bajas tasas de muestreo y la falta de sincronización temporal entre mediciones distantes. Los avances tecnológicos en este ámbito, han sido el desarrollo de las Unidades de Medición Fasorial (PMU). Las PMUs proporcionan mediciones de cierta velocidad (e.g., 30-120 Hz) de fasores, crucialmente sincronizadas mediante una marca de tiempo global (GPS), ofreciendo un análisis del estado del sistema [9] de manera más eficiente, lo que permite una mejor adquisición de los datos para los análisis de la dinámica del sistema.

Este trabajo se alinea con los lineamientos de la Secretaría de Ciencia, Humanidades, Tecnología e Innovación (Secihti) bajo el Eje de Cambio Climático y Gestión de Riesgos, buscando fortalecer las capacidades tecnológicas del Estado mexicano en el sector energético, buscando algoritmos que mejoren el monitoreo de las dinámicas electromecánicas de la red, previniendo así los riesgos asociados con la inestabilidad oscilatoria.

1.1 ANTECEDENTES

La disponibilidad de flujos de datos de PMUs abre dos vías principales para el análisis modal basado en mediciones: el análisis de datos ambiente (ambient data) durante la operación normal y el análisis transitorio (ringdown) tras una perturbación severa [8], [10]. Por ejemplo, las fallas transitorias en la red generan una aceleración en los rotores de los generadores, produciendo así una desviación en la frecuencia del sistema y otras mediciones eléctricas, por ejemplo, el flujo de potencia, voltaje, corriente, entre otras.

La clasificación de los métodos de estimación, con análisis transitorios para estimar los modos de oscilación se subdividen en un principio en métodos lineales y no lineales, los métodos lineales se aplican la suposición de que los modos de oscilación no varían significativamente durante el periodo de análisis, mientras que los métodos no lineales, reconocen que los sistemas son no lineales hasta cierto punto de operación y suponen que la respuesta posterior a una falla o perturbación es principalmente no lineal. A su vez, se subdividen a su vez en métodos paramétricos y no paramétricos [10].

Los métodos paramétricos hacen la identificación sobre modelos matemáticos limitados del sistema, trabajan con los datos para hacer inferencias sobre el sistema que los genera, y así estimar los parámetros del modelo a priori y así determinan valores instantáneos de frecuencia y amortiguamiento, mientras que los métodos no paramétricos trabajan con los datos directamente para estimar las características de los propios datos, se suelen utilizar técnicas en el dominio de la frecuencia, como la transformada de Fourier, para estimar

los modos de oscilación, en este contexto, estos métodos no suelen proveer información directa del amortiguamiento [10].

Los métodos lineales se subdividen en dos clases: las técnicas del dominio del tiempo y las técnicas del dominio de la frecuencia. Las técnicas del dominio de la frecuencia como la identificación en el dominio de la frecuencia o identificación por la transformada Z, ajustan el modelo basado en el espectro de la frecuencia de los datos medidos. Por otro lado, las técnicas del dominio del tiempo, como lo son Prony, Algoritmo de Realización del Sistema Propio (ERA) y Matrix Pencil, ajustan el modelo basado en los datos medidos en el dominio del tiempo [10].

El primer método aplicado a sistemas de potencia fue el método de Prony, surgió como una herramienta matemática a finales de XVIII, pero su aplicación a sistemas de potencia se dio a conocer en 1990 con la publicación del trabajo del Dr. John Hauer y colaboradores [8]. Desde entonces, el análisis de Prony se convirtió en una de las herramientas más utilizadas por los operadores de sistemas de potencia para estimar las frecuencias y amortiguamientos a partir de registros reales. Ejemplo de esto, es la Administración de Energía de Bonneville (BPA) de Estados Unidos, que usaron el método de Prony sobre perturbaciones controladas por el operador para obtener modelos lineales de señales que puedan usarse para el diseño de controladores. También se ha usado para analizar eventos reales de gran escala, como el apagón de 1996 en el oeste de Norteamérica, y ha formado parte de sistemas de monitoreo en lugares como Hydro-Quebec, Australia y Nueva Zelanda [8].

De las técnicas analizadas se hace una clara distinción entre las técnicas que aplican para una sola señal o mono variables, y las técnicas que aplican para múltiples señales o multivariadas, las cuales empezaron a aparecer a partir de 1999 en [11], y que han tenido un auge en los últimos años, debido a la disponibilidad de unidades de medición en campo y su integración en Sistemas de Monitoreo de Área Amplia (WAMS) [9].

1.1.1 TÉCNICAS DE ANÁLISIS MULTIVARIABLES

Para 1999, técnicas como Prony para múltiples señales como en [11], establecen un enfoque multivariable para el análisis modal, lo que mejora la exactitud con la que se estiman los parámetros. Los métodos que basan el análisis en una señal presentan menores ventajas en comparación con los métodos multivariados, ya que de una sola señal no se pueden extraer los patrones dinámicos globales del sistema, y en ocasiones los modos de oscilación pueden no ser observables en ciertas señales. Por lo que los métodos multivariados presentan una ventaja significativa al aprovechar la información contenida en múltiples señales medidas en diferentes ubicaciones del sistema eléctrico de potencia.

Después de Prony multivariable [11], en 2007 el doctor Messina y colegas mediante funciones ortogonales empíricas aplican la SVD a la matriz de datos para extender los patrones propios y temporales de mayor energía [12]. Una técnica que reduce el tiempo

de cómputo usando las mismas funciones empíricas ortogonales particionando la red se presenta en [13]. En 2012 se realiza una extensión que no solo proporciona la variabilidad temporal de la oscilación de baja frecuencia, sino que también calcula la distribución espacial de los modos de oscilación polarizados (POM) relevantes sin necesidad de experiencia previa del sistema [14]. 2014 fue el año para una expansión multivariable basada en un análisis de Fourier para datos ringdowns, aquí se aplican las tendencias de las oscilaciones observadas en los picos de amplitud en el dominio de la frecuencia, usando la FFT [15].

En 2015, el doctor Barocio y colegas mediante una descomposición dinámica de modos (DMD) aproximan el operador de Koopman global, aproximando funciones de Koopman utilizando dos conjuntos de secuencias de datos ordenadas temporalmente [16]. En 2016, se usan técnicas de reducción lineal más avanzadas que analizan la geometría del manifold formado por todos los datos del sistema en un espacio de alta resolución [17]. Para 2018 se propone una respuesta directa a la falla de observabilidad del CWT estándar, combinando la información de todos los canales antes de la estimación para encontrar modos que podrían estar ocultos en canales individuales [18]. En 2019 una extensión MIMO del Vector Fitting es aplicada para múltiples señales simultáneas [19], [20].

Más recientemente, en 2023, el doctor Zamora-Méndez propone una descomposición iterativa de valores propios basado en una extensión de las matrices de Hankel para múltiples señales [21] y en 2024 Rodríguez-Soto, E. Barocio y colaboradores extendieron el método DMD multivariable que utiliza una corrección espacio-temporal entre PMUs para mejorar los datos faltantes y outliers utilizando las distancias de Mahalanobis [22]. En el año actual, técnicas como el análisis independiente de componentes rápido (FastICA) junto con el algoritmo de búsqueda de coincidencias no lineal (NMP) ayuda a la mejora de estimación de parámetros modales a partir de datos contaminados con ruido [23].

El análisis de los artículos revisados, se observa que los métodos adquirieron mayor robustez en la estimación de los modos de oscilación, al pasar de técnicas univariadas a multivariadas, y que la tendencia actual es la de mejorar la estimación de los modos de oscilación. A la par, una tendencia en auge identificada es la estimación de patrones espacio-temporales de las oscilaciones de baja frecuencia, que permiten caracterizar y mejorar la interpretación de el comportamiento global del sistema frente a este tipo de oscilaciones.

1.1.2 TÉCNICAS QUE APROXIMAN PATRONES DINÁMICOS

Trudonsky en 1999 introduce un uso concreto de las técnicas multivariadas, la sintonización de controles [11]. Pero sin un diferenciador sobre las técnicas mono variables, que ya se utilizaban para los mismos objetivos. En 2012, Yang y colaboradores proponen una utilidad operativa los patrones espaciales calculados, proponiendo una frontera de

osilacion energetica [14], Jiang en 2017 y Li 2018 declaran el uso de para guias que controlan las conexiones en islas, lo que minimiza la propagación y el impacto de los apagones en cascada probocados por las oscilaciones de baja frecuencia [18], [24].

En 2020, Li y colaboradores formulan el problema de manera holistica [25] nombrando los modos dominantes, mode shape, factores de participación y grupos coherentes, para describir las características dinamicas de las osilaciones. Yiang en 2020 lo resuelve y lo conecta con tres desiciones de operacion distintas [26]. Estos ultimos tres patrones tienen dependencia espacial, por lo que no existen para una sola señal, validando desde un punto de vista operacional la tendencia de los algoritmos por estimar los patrones dinamicos de oscilacion.

Los modos dominantes son los que tienen mayor impacto durante los fenomenos transitorios que experimenta la red, de manera similar a la frecuencia y amortiguamiento estimados de los modos de oscilacion dominante, los mode shapes, factores de participación y los grupos coherentes tambien describen de manera significativa propiedades dinamicas de las osilaciones electromecanicas del sistema, pueden contribuir a la mitigacion de la oscilacion y la toma de desiciones de operacion.

Por ejemplo, los mode shape podrian ayudar a los operadores del sistema a planificar las desconexiones optimas de generadores o lineas de transmision para aumentar la amortiguacion de un modo de oscilacion dominate. Los factores de participacion pueden ayudar a aportar informacion de la observabilidad y la controlabilidad de cada generador asociado a un modo de osilacion espesifico, y a futuro, escoger la mejor ubicacion del PSS para amortiguar la oscilacion. Los grupos coherentes de generadores se pueden utilizar para dividir la red electrica completa en islas independientes, disminuyendo asi, el riesgo de la propagacion de apagones en cascada causadas por las osilaciones electromecanicas con amplitud creciente [18], [24], [25], [26].

La estimacion de estos patrones varia segun la tecnica principal usada para la primera estimacion de los modos de oscilacion, y algunos autores usa metodos diferentes del principal para estimar los patrones dinamicos, lo cual divide a las familias de algoritmos en grupos, las que estiman los patrones dinamicos de manera directa y los que lo hacen de manera indirecta o usan otro metodo diferente del principal para estimar los patrones dinamicos. Con estas observaciones, y usando una base de 32 articulos revisados, se propone una clasificacion de los articulos en funcion de los patrones dinamicos estimados, como se observa en la Fig. 1.1.

El enfoque de los patrones dinamicos es una herramienta para entender en comportamiento espacio temporal de la osilacion en el sistema electrico de potencia, como se ve en la Fig. 1.1. La estimacion de estos patrones varia dependiendo de la tecnica utilizada, por lo que es importante conocer las características de cada tecnica para poder elegir la mas adecuada para el analisis de los datos de PMUs.





Figura 1.1: Clasificación de Artículos en función de los patrones dinámicos estimados

1.1.3 FAMILIAS DE ALGORITMOS

Las dos clasificaciones presentadas responden preguntas distintas sobre el mismo conjunto de 32 trabajos. La Fig. 1.2 ordena las técnicas según el objeto algebraico que construyen a partir de la matriz de datos $P \times N$, y separa las familias que derivan un modelo dinámico explícito —y con él frecuencia y amortiguamiento— de aquellas que solo recuperan estructura espacial o frecuencia instantánea. La Fig. 1.1 ordena los mismos trabajos según el patrón que cada método entrega, distinguiendo entre los que lo calculan

con una métrica propia del algoritmo y los que lo derivan de otra salida. La primera describe cómo está construido el método; la segunda, qué produce.



Características operativas por familia

Familia	Régimen	Solución	Patrones
F1 Predicción lineal	ringdown	forma cerrada	solo forma modal; ninguno alcanza los tres
F2 Espacio de estados	ringdown / ambiente	forma cerrada	los tres (ERA)
F3 Operador en observables	ringdown	cerrada o iterativa	los tres (DMD, proyección variable)
F4 Ajuste racional	ringdown	iterativa	forma modal, índices de participación
F5 Descomp. estadística	ambiente / ringdown	forma cerrada	forma modal, índices de participación
F6 Variedad no lineal	ambiente / ringdown	forma cerrada	solo grupos coherentes
F7 Tiempo-frecuencia	ringdown / ambiente	cerrada o iterativa	forma modal más uno de los otros dos

Figura 1.2: Clasificación de Técnicas Multivariantes (WAMS)

Del cruce de ambas figuras se obtiene el panorama siguiente. La forma modal es el patrón más extendido: la calculan Trudnowski y Hauer mediante Prony multiseñal [11], Susuki y Mezić mediante modos de Koopman [35], Tashman y Venkatasubramanian mediante Fourier multidimensional [15] y Esquivel Prado y Jurado mediante funciones ortogonales empíricas particionadas [13]. Los índices de participación aparecen junto a la forma modal en Yang y Rehtanz con SVD compleja [14], en Zamora y Paternina con filtros Taylor-Fourier [40] y en Bañuelos y Nuño-Ayón con ajuste espectral [20]. Los

grupos coherentes los calculan Arvizu y Mesina mediante mapas de difusión [17] y, junto con la forma modal, Jiang y Yuan [24] y Li y Cui [18] mediante descomposiciones wavelet multicanal. Solo tres métodos entregan los tres patrones espaciales con métrica propia: la descomposición dinámica de modos de Barocio y Messina [16], la realización del eigensistema de Li y Jiang [25] y la proyección variable optimizada de Jiang y Kou [26].

Situados esos tres métodos sobre la Fig. 1.2, se advierte que pertenecen a las familias de realización en espacio de estados y de operadores lineales. La familia de predicción lineal y ajuste exponencial —la que reúne a Prony multiseñal, matrix pencil y Tufts-Kumaresan— no registra ningún método que alcance los tres patrones con el mismo método, pese a ser la familia de la que proviene el primer método aplicado a sistemas de potencia y la única que combina solución en forma cerrada con ventanas cortas de ringdown. Que otras dos familias sí resuelvan el problema indica que no se obedece a una limitación de la predicción lineal, sino a que sus formulaciones multivariantes se han orientado a mejorar la exactitud de la frecuencia y el amortiguamiento y no a recuperar la estructura espacial contenida en el subespacio truncado.

Dentro de la familia de predicción lineal, Tufts-Kumaresan ocupa una posición particular. Prony y matrix pencil ajustan el modelo sin construir un subespacio reducido explícito, mientras que Tufts-Kumaresan incorpora el truncamiento por descomposición en valores singulares sobre la matriz de predicción hacia atrás [27], paso del que resulta un subespacio de señal de dimensión reducida. Puesto que los mode shape, los índices de participación y los grupos coherentes se calculan precisamente a partir de la estructura de ese subespacio, la maquinaria necesaria ya está presente en el algoritmo; lo que no está es la dimensión espacial, ausente por su formulación mono variable. Su aplicación reciente a sistemas de potencia [32] conserva esa formulación y se limita a la estimación de modos dominantes.

1.2 JUSTIFICACIÓN

Las figuras 1.2 y 1.1 muestran que la cobertura completa de patrones dinámicos se ha alcanzado únicamente mediante familias cuya solución es iterativa o exige la construcción de un modelo en espacio de estados de orden elevado. El reporte del grupo de trabajo del IEEE señala que un sistema de alarma modal competente incorpora amplitud, amortiguamiento y frecuencia, y que los patrones de interacción son necesarios para asociar el modo con instalaciones concretas [8, Cap. 4]. Atender ese cuarto elemento desde una familia de solución en forma cerrada y ventana acotada es, por tanto, un problema abierto con consecuencias operativas directas.

La creciente integración de recursos energéticos renovables y la operación de los sistemas de potencia cerca de sus límites de estabilidad han aumentado la naturaleza no

lineal de las oscilaciones. Los métodos actuales de monitoreo enfrentan desafíos críticos que justifican el desarrollo de una nueva metodología capaz de procesar información de manera robusta y global.

En este contexto, la presente investigación se alinea estratégicamente con el Programa Nacional Estratégico (PRONACE) bajo el Eje Estratégico de Cambio Climático y Gestión de Riesgos, contribuyendo directamente al desarrollo de modelos tecnológicos de bajo consumo de energía aplicados a la ciudad. La transición hacia un modelo energético sustentable requiere la ampliación en gran medida de las redes inteligentes (Smart Grids) y la integración de micro-redes y generación renovable. Sin embargo, la intermitencia de estas fuentes limpias introduce dinámicas complejas que amenazan la confiabilidad del suministro. El algoritmo multivariable propuesto actúa como una propuesta tecnológica, pues al garantizar la identificación modal sobre fallas transitorias, permite operar estas redes modernas de manera segura y eficiente.

1.3 OBJETIVOS

1.3.1 GENERAL

La ausencia de métodos de predicción lineal que aproximen los patrones dinámicos con métrica propia obedece a su formulación monocanal y no a una limitación de la familia. En consecuencia, una extensión multivariable basado en el algoritmo Tufts-Kumaresan [27], [32], capaz de aproximar los patrones dinámicos de la oscilación a partir del subespacio de señal., construida sobre una matriz de predicción lineal hacia atrás apilada y truncada mediante descomposición en valores singulares, permite calcular formas modales, índices de participación y grupos coherentes a partir del subespacio de señal, conservando la solución en forma cerrada y la ventana corta de ringdown que caracterizan a la familia.

1.3.2 ESPECÍFICOS

- Formular matemáticamente la extensión de la matriz de predicción lineal hacia atrás del método Kumaresan-Tufts para soportar entradas de múltiples señales.
- Implementar estrategias de truncamiento de valores singulares para discriminar, bajo un criterio formal, entre los modos dominantes del sistema y el ruido de medición.
- Validar el desempeño del algoritmo propuesto mediante señales sintéticas y simulaciones de sistemas de potencia de prueba: (i) comparando su precisión y tiempo de ejecución frente a métodos clásicos como Prony Multiseñal, ERA y Matrix Pencil bajo diferentes escenarios de ruido para compara y (ii) exactitud de los patrones frente a metodos multivariable.

- Estimar los mode shape, los factores de participación, los grupos coherentes de los modos identificados con metricas propias para caracterizar completamente la dinámica electromecánica del sistema. Graficar y visualizar los modos y patrones dinamicos estimados.

1.4 HIPÓTESIS

Con una extensión multivariable de la tecnica Tufts-Kumaresan (M-TK), mediante una descomposición de valores singulares sobre una matriz de predicción apilada, se espera la identificación unificada y analisis de patrones dinamicos de modos electromecánicos.

1.5 METODOLOGÍA

- Revisión bibliográfica y estado del arte: Análisis de técnicas de identificación modal para sistemas de potencia.
- Selección e implementación de algoritmos: Selección de técnicas multivariables representativas (ERA, Prony multivariable, etc.). Implementación computacional de los algoritmos seleccionados
- Desarrollo de casos de estudio: Creación de modelos de simulación en software especializado (MATLAB/Simulink, DigSILENT, etc.). Diseño de escenarios con diferentes tipos de perturbaciones y condiciones operativas.
- Validación y evaluación: Pruebas de los algoritmos con datos sintéticos y reales. Comparación del desempeño entre métodos multivariables. Análisis de sensibilidad frente a ruido y posiblemente missing data o outliers.
- Análisis de resultados: Análisis estadístico de los resultados obtenidos. Elaboración de conclusiones y recomendaciones.

1.6 CRONOGRAMA

A continuación, se presenta la planeación de las actividades a desarrollar durante el periodo 2025-2026:

Tabla 1.1: Cronograma de actividades (Agosto 2025 - Diciembre 2026)

Actividad / Semanas	2025																2026															
	Ago.				Sep.				Oct.				Nov.				Dic.				Ene.				Feb.				Mar.			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4				
Periodo Vacacional																	V	V	V	V												
Clases formativas	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X										V				
Revisión de tesis																X	X															
Antecedentes, Justificación																				X	X	X	X	X	X							
Objetivos e Hipótesis																					X	X	X	X								
Metodología, Organización																					X	X	X	X	X	X	X					
Revisión bibliográfica																				X	X	X	X	X	X	X	X					
Implementación algoritmos																										X	X	X				

[illegible]

REFERENCIAS

- [1] J. D. Glover, M. S. Sarma, T. J. Overbye y A. Birchfield, *Power System Analysis and Design*, 6.^a ed. Boston, MA: Cengage Learning, 2017.
- [2] E. de la Garza Toledo, J. Melgoza y L. de la Garza, *Historia de la industria eléctrica*, 1.^a ed. México: Universidad Autónoma Metropolitana, 1994.
- [3] M. Amin y J. Stringer, «The Electric Power Grid: Today and Tomorrow,» *MRS Bulletin*, vol. 33, n.º 4, págs. 347-354, 2008.
- [4] P. Kundur, *Power System Stability and Control* (EPRI Power System Engineering Series). New York: McGraw-Hill, 1994.
- [5] P. Kundur et al., «Definition and Classification of Power System Stability IEEE/CIGRE Joint Task Force on Stability Terms and Definitions,» *IEEE Transactions on Power Systems*, vol. 19, n.º 3, págs. 1387-1401, 2004.
- [6] N. Hatziargyriou et al., «Definition and Classification of Power System Stability - Revisited & Extended,» *IEEE Transactions on Power Systems*, vol. 36, n.º 4, págs. 3271-3281, 2021.
- [7] G. J. Rogers, R. T. Elliott, D. J. Trudnowski, F. Wilches-Bernal, D. Osipov y J. H. Chow, *Power System Oscillations: An Introduction to Oscillation Analysis and Control*, Second. New York: Springer, 2025.
- [8] J. Sanchez-Gasca et al., «Identification of Electromechanical Modes in Power Systems,» English, en *IEEE Task Force Report, Special Publication TP462*. United States: IEEE, 2012, ISBN: -.
- [9] J. F. Hauer, D. J. Trudnowski y J. G. DeSteese, «A Perspective on WAMS Analysis Tools for Tracking of Oscillatory Dynamics,» en *IEEE Power Engineering Society General Meeting*, 2007.
- [10] J. Thambirajah, E. Barocio y N. F. Thornhill, «Comparative review of methods for stability monitoring in electrical power systems and vibrating structures,» *IET Generation, Transmission and Distribution*, vol. 4, n.º 10, págs. 1086-1103, 2010.
- [11] D. J. Trudnowski, J. M. Johnson y J. F. Hauer, «Making Prony analysis more accurate using multiple signals,» *IEEE Transactions on Power Systems*, vol. 14, n.º 1, págs. 226-231, 1999.
- [12] A. R. Messina y V. Vittal, «Extraction of Dynamic Patterns From Wide-Area Measurements Using Empirical Orthogonal Functions,» *IEEE Transactions on Power Systems*, vol. 22, n.º 2, págs. 682-692, 2007.

- [13] P. E. Prado, C. E. Castañeda y F. Jurado, «Partitioned modal extraction applied to power system wide-area measurements using empirical orthogonal functions,» *Electric Power Systems Research*, vol. 123, págs. 185-191, 2015.
- [14] D. Yang, C. Rehtanz, Y. Li y D. Cai, «Identification of dominant oscillation mode using complex singular value decomposition method,» *Electric Power Systems Research*, vol. 83, n.º 1, págs. 227-236, 2012.
- [15] Z. Tashman, H. Khalilinia y V. Venkatasubramanian, «Multi Dimensional Fourier Ringdown Analysis for Power Systems Using Synchrophasors,» *IEEE Transactions on Power Systems*, vol. 29, n.º 2, págs. 731-741, 2014.
- [16] E. Barocio, B. C. Pal, N. F. Thornhill y A. R. Messina, «A Dynamic Mode Decomposition Framework for Global Power System Oscillation Analysis,» *IEEE Transactions on Power Systems*, vol. 30, n.º 6, págs. 2902-2912, 2015.
- [17] C. M. C. Arvizu y A. R. Messina, «Dimensionality Reduction in Transient Simulations: A Diffusion Maps Approach,» *IEEE Transactions on Power Delivery*, vol. 31, n.º 5, págs. 2379-2389, 2016.
- [18] X. Li, H. Cui, T. Jiang, Y. Xu, H. Jia y F. Li, «Multichannel continuous wavelet transform approach to estimate electromechanical oscillation modes, mode shapes and coherent groups from synchrophasors in bulk power grids,» *International Journal of Electrical Power and Energy Systems*, vol. 96, págs. 222-237, 2018.
- [19] R. Schumacher, G. H. C. Oliveira y R. Kuiava, «A multi-signal instrumental variable vector fitting method for estimating inter-area electromechanical modes of power systems,» *International Journal of Electrical Power and Energy Systems*, vol. 111, págs. 1-13, 2019.
- [20] E. S. Bañuelos-Cabral et al., «Spectral fitting approach to estimate electromechanical oscillation modes and mode shapes by using vector fitting,» *Electric Power Systems Research*, vol. 176, pág. 105 958, 2019.
- [21] A. Zamora-Mendez, R. D. R. de Luna, J. A. de la O Serna, J. H. Chow y M. R. A. Paternina, «Electromechanical Modes Identification Based on an Iterative Eigenvalue Decomposition of the Hankel Matrix,» *IEEE Transactions on Power Systems*, vol. 38, págs. 155-167, 2023.
- [22] R. D. Rodriguez-Soto, E. Barocio, F. Gonzalez-Longatt, F. R. S. Sevilla y P. Korba, «Robust Three-Stage Dynamic Mode Decomposition for Analysis of Power System Oscillations,» *IEEE Transactions on Power Systems*, vol. 39, n.º 2, págs. 4000-4012, 2024.

- [23] L. Wang, B. Wang, H. Gao, D. Yang, S. Xia y T. T. Lie, «Synchronized Data-Based Identification of Electromechanical Oscillation Modes Using Improved FastICA Considering Measurement Noise,» *IEEE Transactions on Instrumentation and Measurement*, vol. 74, pág. 3 003 413, 2025.
- [24] T. Jiang, H. Yuan, G. Li, H. Jia y F. Li, «Spatial-temporal decomposition approach for systematically tracking dominant modes, mode shapes and coherent groups in power systems,» *IET Generation, Transmission & Distribution*, vol. 11, n.º 8, págs. 1889-1900, 2017. doi: <https://doi.org/10.1049/iet-gtd.2016.0551>
- [25] X. Li et al., «An Eigensystem Realization Algorithm Based Data-Driven Approach for Extracting Electromechanical Oscillation Dynamic Patterns from Synchrophasor Measurements in Bulk Power Grids,» *International Journal of Electrical Power and Energy Systems*, vol. 116, pág. 105 549, 2020. doi: [10.1016/j.ijepes.2019.105549](https://doi.org/10.1016/j.ijepes.2019.105549)
- [26] T. Jiang, X. Kou, G. Liu y H. Yuan, «Synergistic Data Analytics for Electromechanical Oscillation in Electric Power Systems,» *International Journal of Electrical Power and Energy Systems*, vol. 135, pág. 107 610, 2022. doi: [10.1016/j.ijepes.2021.107610](https://doi.org/10.1016/j.ijepes.2021.107610)
- [27] R. Kumaresan y D. W. Tufts, «Estimating the Parameters of Exponentially Damped Sinusoids and Pole-Zero Modeling in Noise,» *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 30, n.º 6, págs. 833-840, 1982. doi: [10.1109/TASSP.1982.1163974](https://doi.org/10.1109/TASSP.1982.1163974)
- [28] C. A. Ordóñez y M. A. Ríos, «Electromechanical Modes Identification Based on Sliding-window Data from a Wide-area Monitoring System,» *Electric Power Components and Systems*, vol. 41, n.º 13, págs. 1264-1279, 2013. doi: [10.1080/15325008.2013.816982](https://doi.org/10.1080/15325008.2013.816982)
- [29] M. R. A. Paternina, R. K. Tripathy, A. Zamora-Mendez y D. Dotta, «Identification of electromechanical oscillatory modes based on variational mode decomposition,» *Electric Power Systems Research*, vol. 167, págs. 71-85, 2019. doi: [10.1016/j.epsr.2018.10.014](https://doi.org/10.1016/j.epsr.2018.10.014)
- [30] N. Ma y D. Wang, «Extracting Spatial-Temporal Characteristics of Frequency Dynamic in Large-Scale Power Grids,» *IEEE Transactions on Power Systems*, vol. 34, n.º 4, págs. 2654-2662, 2019. doi: [10.1109/TPWRS.2019.2896327](https://doi.org/10.1109/TPWRS.2019.2896327)
- [31] A. Almunif, L. Fan y Z. Miao, «A tutorial on data-driven eigenvalue identification: Prony analysis, matrix pencil, and eigensystem realization algorithm,» *International Transactions on Electrical Energy Systems*, vol. 30, n.º 4, e12283, 2020. doi: [10.1002/2050-7038.12283](https://doi.org/10.1002/2050-7038.12283)

- [32] M. A. Moghdam, R. Noroozian y S. Jalilzadeh, «Improving the accuracy and the estimation time of inter-area modes in power system based on Tufts-Kumaresan algorithm,» *International Journal of Modelling and Simulation*, vol. 44, n.º 3, págs. 126-135, 2024. DOI: 10.1080/02286203.2022.2161443
- [33] Y. Chen, F. Wu, L. Shi, Y. Li, P. Qi y X. Guo, «Identification of Sub-Synchronous Oscillation Mode Based on HO-VMD and SVD-Regularized TLS-Prony Methods,» *Energies*, vol. 17, n.º 20, pág. 5067, 2024. DOI: 10.3390/en17205067
- [34] R. D. R. de Luna, J. A. de la O Serna, M. R. A. Paternina, A. Zamora-Mendez y A. López-Ríos, «Bessel and cosine filtering approaches for electromechanical modes identification,» *International Journal of Electrical Power and Energy Systems*, vol. 170, pág. 110 869, 2025. DOI: 10.1016/j.ijepes.2025.110869
- [35] Y. Susuki e I. Mezić, «Nonlinear Koopman Modes and Power System Stability Assessment Without Models,» *IEEE Transactions on Power Systems*, vol. 29, n.º 2, págs. 899-907, 2014. DOI: 10.1109/TPWRS.2013.2287235
- [36] D. J. Trudnowski, J. Follum, R. T. Elliott, D. A. Schoenwald y J. W. Pierre, «Characterizing the Oscillatory Properties of Bulk Electric Systems,» *IEEE Access*, vol. 13, págs. 32 883-32 899, 2025. DOI: 10.1109/ACCESS.2025.3543457
- [37] J. Ramos, R. Jimenez y E. Barocio, «Visualization of interarea oscillations using an extended subspace identification technique,» en *2013 North American Power Symposium (NAPS)*, 2013, págs. 1-6. DOI: 10.1109/NAPS.2013.6666931
- [38] C. M. C. Arvizu y A. R. Messina, «Extraction of spatiotemporal patterns from measured data via nonlinear Laplacian spectral analysis,» en *2016 IEEE Power and Energy Society General Meeting (PESGM)*, 2016, págs. 1-5. DOI: 10.1109/PESGM.2016.7741965
- [39] P. Esquivel y C. E. Castañeda, «Spatio-temporal statistical identification methodology applied to wide-area monitoring schemes in power systems,» *Electric Power Systems Research*, vol. 111, págs. 52-61, 2014. DOI: 10.1016/j.epsr.2014.01.024
- [40] A. Zamora, V. M. Venkatasubramanian, J. A. de la O Serna, J. M. Ramirez y M. R. A. Paternina, «Multi-dimensional ringdown modal analysis by filtering,» *Electric Power Systems Research*, vol. 143, págs. 748-759, 2017. DOI: 10.1016/j.epsr.2016.10.022
- [41] M. Zuhaib y M. Rihan, «Identification of Low-Frequency Oscillation Modes Using PMU Based Data-Driven Dynamic Mode Decomposition Algorithm,» *IEEE Access*, vol. 9, págs. 49 434-49 447, 2021. DOI: 10.1109/ACCESS.2021.3068227

CAPITULO 2

MARCO TEÓRICO

RESUMEN

Las oscilaciones electromecánicas de baja frecuencia limitan la capacidad de transferencia de los sistemas eléctricos interconectados y, cuando están pobremente amortiguadas, pueden desencadenar apagones de gran escala. Su diagnóstico tradicional mediante análisis de eigenvalores exige un modelo preciso y parámetros actualizados, difíciles de mantener en redes reales. Extraer las propiedades modales — modos dominantes, formas modales, factores de participación y grupos coherentes — directamente de mediciones sincrofasoriales, sin un modelo del sistema y con robustez frente al ruido es un problema abierto. Se propone un algoritmo de identificación que combine la predicción lineal multicanal de Tufts–Kumaresan, basada en el truncamiento de la descomposición en valores singulares permite aproximar los parámetros modales con exactitud. El objetivo es establecer el marco teórico que fundamenta esa cadena, deduciendo el modelo de señal desde la física del generador síncrono y rigORIZANDO cada etapa de estimación. El capítulo articula una estructura teórica invertible que (i) deriva el modelo de exponenciales amortiguadas como consecuencia de la respuesta libre del sistema y no como postulado; (ii) sustenta el truncamiento de la SVD como filtro óptimo y la selección de orden por umbral duro óptimo; (iii) conecta las cantidades medibles con los eigenvectores del modelo de estados; y (iv) formaliza la identificación de grupos coherentes por coseno director y agrupamiento espectral. El marco se valida contra la literatura de identificación modal basada en mediciones sobre el sistema de prueba de 16 generadores y 68 buses.

2.1 INTRODUCCIÓN DEL CAPÍTULO

Este capítulo construye, de manera deductiva, el puente entre la física de las oscilaciones electromecánicas y los algoritmos de identificación modal basados en mediciones sincrofasoriales que sustentan esta tesis. La exposición sigue una cadena de implicaciones: se parte de las ecuaciones de oscilación del generador síncrono bajo el modelo clásico

[1], se linealiza alrededor del punto de operación para obtener el modelo de estados cuyo espectro define los modos electromecánicos, y se demuestra — mediante la transformación modal y la respuesta libre del sistema — que toda señal registrada por una unidad de medición fasorial en régimen de *ring-down* obedece un modelo de suma de exponenciales complejas amortiguadas. Esta derivación convierte el modelo de señal en consecuencia de la física del sistema, y no en postulado, y delimita su dominio de validez: la banda electromecánica (0,1–2 Hz).

Sobre esa base se desarrolla la maquinaria de estimación: la formulación discreta y su mapeo al plano z ; la predicción lineal hacia atrás multicanal de Tufts–Kumaresan y su mecanismo de separación señal–ruido [2]; el truncamiento de la SVD como filtro selección de orden por energía y por umbral duro [3], [4]; la estimación de amplitudes mediante sistemas de Vandermonde; y el refinamiento por proyección variable [5]. La parte final traduce los parámetros en patrones dinámicos interpretables: formas modales, índices de participación y grupos coherentes **li2018cwt**, [6], [7]. Se incluye, además, el diseño de los estudios experimentales que validan la selección del orden del predictor L , la del orden del modelo M y las formulaciones de optimización con restricciones de subespacio.

2.1.1 DINÁMICA DE OSCILACIONES ELECTROMECAÑICAS

ECUACIONES DE SWING DEL GENERADOR SÍNCRONO

La dinámica de cada generador i en un sistema de n_g máquinas ($i = 1, \dots, n_g$) se describe mediante las **ecuaciones de swing**:??

$$\dot{\delta}_i = \omega_i - \omega_s \quad (2.1)$$

$$\dot{\omega}_i = \frac{\omega_s}{2H_i} \left(P_{m,i} - P_{e,i}(\delta) - D_i(\omega_i - \omega_s) \right) \quad (2.2)$$

Las ecuaciones (2.1)–(2.2) corresponden al **modelo clásico** del generador síncrono [1]: la máquina se representa como una fuente de voltaje interna de magnitud constante E'_i detrás de la reactancia transitoria $x'_{d,i}$, con potencia mecánica $P_{m,i}$ constante en la ventana de análisis y con todos los efectos de amortiguamiento (devanados amortiguadores, cargas sensibles a la frecuencia, etc.) agregados en el coeficiente D_i . Este nivel de modelado es suficiente para caracterizar la dinámica electromecánica de interés, pues los modos de oscilación de nuestro interés entre rotores quedan determinados por el intercambio de energía cinética y potencia sincronizante entre máquinas [1], [8].

Parámetros (todas las potencias en por unidad sobre una base común S_{base}):

- δ_i : ángulo del rotor respecto a la referencia síncrona (rad);

- ω_i : velocidad angular del rotor (rad/s);
- H_i : constante de inercia, $H_i = \frac{1}{2} J_i \omega_s^2 / S_{\text{base}}$ (s);
- D_i : coeficiente de amortiguamiento (p.u. de par por p.u. de desviación de velocidad, adimensional);
- $P_{m,i}$: potencia mecánica de entrada (p.u.);
- $P_{e,i}(\delta)$: potencia eléctrica entregada — función no lineal de los ángulos de rotor $\delta = [\delta_1, \dots, \delta_{n_g}]^\top$ a través de la red a nodos de generación (p.u.);
- $\omega_s = 2\pi f_s$: velocidad síncrona de referencia (rad/s).

LINEALIZACIÓN ALREDEDOR DEL PUNTO DE OPERACIÓN

Para analizar la estabilidad de pequeña señal, se linealiza el sistema alrededor del punto de equilibrio (δ^0, ω^0) ; en régimen permanente se cumple $(\dot{\delta}_i = 0, \dot{\omega}_i = 0)$:

$$P_{m,i} = P_{e,i}(\delta^0), \quad \omega_i^0 = \omega_s \quad (2.3)$$

Se definen las variables de estado de perturbación (desviaciones):

$$\Delta\delta = \delta - \delta^0, \quad \Delta\omega = \omega - \omega^0 \quad (2.4)$$

Linealizando la primera ecuación de oscilación:

$$\Delta\dot{\delta} = \Delta\omega \quad (2.5)$$

Expandiendo la serie de Taylor de primer orden de $P_{e,i}(\delta)$ alrededor de δ^0 y usando la condición de equilibrio se linealiza la segunda ecuación de oscilación:

$$\Delta\dot{\omega}_i = \frac{\omega_s}{2H_i} \left(- \sum_{j=1}^{n_g} \frac{\partial P_{e,i}}{\partial \delta_j} \Big|_{\delta^0} \Delta\delta_j - D_i \Delta\omega_i \right) \quad (2.6)$$

Las derivadas parciales evaluadas en el punto de operación definen los **coeficientes de potencia sincronizante** [1]:

$$K_{ij} = \frac{\partial P_{e,i}}{\partial \delta_j} \Big|_{\delta^0}, \quad i, j = 1, \dots, n_g, \quad (2.7)$$

que representan el acoplamiento entre las máquinas i y j a través de la red y representa el cambio en la potencia eléctrica para un cambio en el punto de equilibrio. Agrupando las desviaciones en el vector de estados $\Delta\mathbf{x} = [\Delta\delta^\top \ \Delta\omega^\top]^\top \in \mathbb{R}^{2n_g}$, el sistema linealizado adquiere la forma canónica de espacio de estados en lazo abierto (movimiento libre):

$$\Delta \dot{\mathbf{x}} = \mathbf{A} \Delta \mathbf{x}, \quad \mathbf{A} = \begin{bmatrix} \mathbf{0} & \mathbf{I}_{n_g} \\ -\omega_s \mathbf{M}^{-1} \mathbf{K} & -\omega_s \mathbf{M}^{-1} \mathbf{D} \end{bmatrix} \in \mathbb{R}^{2n_g \times 2n_g}, \quad (2.8)$$

donde $\mathbf{M} = \text{diag}(2H_1, \dots, 2H_{n_g})$, $\mathbf{D} = \text{diag}(D_1, \dots, D_{n_g})$ y $\mathbf{K} = [K_{ij}] \in \mathbb{R}^{n_g \times n_g}$ es la matriz de coeficientes de potencia sincronizante. La estabilidad de pequeña señal del punto de operación queda gobernada por los eigenvalores de $\mathbf{A}$, raíces de la ecuación característica $\det(s\mathbf{I} - \mathbf{A}) = 0$ [1].

SOLUCIÓN MODAL: DEL ESPACIO DE ESTADOS A LA SUMA DE EXPONENCIALES AMORTIGUADAS

Sea $\{\lambda_k\}_{k=1}^{2n_g}$ el espectro de $\mathbf{A}$, con eigenvectores derechos ϕ_k e izquierdos ψ_k que satisfacen

$$\mathbf{A}\phi_k = \lambda_k \phi_k, \quad \psi_k^\top \mathbf{A} = \lambda_k \psi_k^\top, \quad \psi_j^\top \phi_k = \delta_{jk}. \quad (2.9)$$

La transformación $\Delta \mathbf{x} = \Phi \mathbf{z}$, con $\Phi = [\phi_1 \cdots \phi_{2n_g}]$, desacopla (2.8) en $2n_g$ ecuaciones escalares $\dot{z}_k = \lambda_k z_k$, de modo que la respuesta libre ante una perturbación inicial $\Delta \mathbf{x}(0)$ es [1]

$$\Delta \mathbf{x}(t) = \sum_{k=1}^{2n_g} \phi_k \underbrace{(\psi_k^\top \Delta \mathbf{x}(0))}_{c_k} e^{\lambda_k t}. \quad (2.10)$$

Dado que $\mathbf{A}$ es real, los eigenvalores oscilatorios aparecen en pares complejos conjugados $\lambda_k = \sigma_k \pm j\omega_k$; cada par constituye un **modo electromecánico de oscilación** con frecuencia $f_k = \omega_k/2\pi$ y razón de amortiguamiento

$$\zeta_k = \frac{-\sigma_k}{\sqrt{\sigma_k^2 + \omega_k^2}}. \quad (2.11)$$

Cualquier señal medida $x_i(t)$ que sea combinación lineal de los estados — es el caso de desviaciones de velocidad de rotor, frecuencia de bus, potencia activa o ángulos de tensión registrados por un PMU, expresables como $x_i = \mathbf{c}_i^\top \Delta \mathbf{x}$ — tiene la misma estructura espectral:

$$x_i(t) = \sum_{k=1}^{2n_g} \underbrace{(\mathbf{c}_i^\top \phi_k)}_{a_{i,k}} c_k e^{\lambda_k t}, \quad (2.12)$$

lo que justifica, desde la física del sistema, el modelo de suma de exponenciales amortiguadas que adoptan los algoritmos de identificación modal de las secciones siguientes. La amplitud compleja $a_{i,k}$ acopla la *observabilidad* del modo k en el canal i (a través de $\mathbf{c}_i^\top \phi_k$, es decir, de la forma modal) con la *excitación* del modo por la perturbación (a través de c_k) [1].

MODOS ELECTROMECAÑICOS Y SU OBSERVACIÓN MEDIANTE SINCROFASORES (WAMS)

Los modos oscilatorios de (2.10) se clasifican según su extensión geográfica y banda de frecuencia [1], [8]: **modos locales** (una planta contra el resto del sistema, aproximadamente 1–3 Hz) y **modos interárea** (grupos coherentes de generadores oscilando entre sí, por debajo de 1 Hz, típicamente 0,2–1 Hz). Los modos interárea, de bajo amortiguamiento ($\zeta_k < 3\%$) y difícil diagnóstico, limitan las transferencias de potencia y constituyen el objeto principal de la identificación modal [8].

Las unidades de medición fasorial (PMU) de un sistema de monitoreo de área amplia (WAMS) entregan fasores de tensión y corriente, frecuencia y potencias sincronizados vía GPS, con tasas de reporte de 30 a 120 muestras por segundo [8]. Puesto que la banda electromecánica completa se encuentra por debajo de 3 Hz, una tasa de reporte $F_s \geq 30$ Hz satisface holgadamente el criterio de Nyquist ($F_s > 2f_k$) y dota a las señales de la resolución temporal necesaria para aproximar tanto ω_k como σ_k [8]. En contraste, los sistemas SCADA convencionales, con periodos de muestreo del orden de segundos, no resuelven esta dinámica.

Tras una gran perturbación, la respuesta inmediata del sistema es fuertemente no lineal; sin embargo, una vez que las trayectorias se aproximan al nuevo punto de equilibrio, las oscilaciones registradas por los PMU se pueden modelar como la respuesta libre de un sistema lineal [8]. Es en este estado donde el modelo (2.12) es válido y donde operan los algoritmos de predicción lineal desarrollados a continuación.

2.2 FORMULACIÓN DISCRETA Y PREDICCIÓN LINEAL

2.2.1 DEL TIEMPO CONTINUO AL DOMINIO MUESTREADO

Muestreando cada señal $x_i(t)$ de (2.12) con periodo $\Delta t = 1/F_s$, definimos $x_i[n] = x_i(n\Delta t)$ para $n = 0, 1, \dots, N-1$. El modelo continuo de suma de exponenciales amortiguadas se transforma exactamente en

$$x_i[n] = \sum_{k=1}^M a_{i,k} z_k^n, \quad z_k = e^{\lambda_k \Delta t} = e^{(\sigma_k + j\omega_k) \Delta t}, \quad (2.13)$$

donde $M \leq 2n_g$ es el número de modos efectivamente observables en la ventana de datos. Puesto que las señales medidas son reales, los polos z_k y las amplitudes $a_{i,k}$ aparecen en pares complejos conjugados, de modo que M es el número de exponenciales complejas y K el número de modos oscilatorios físicos. Los polos en tiempo discreto contienen toda la información modal:

$$z_k = e^{(\sigma_k + j\omega_k)\Delta t}, \quad (2.14)$$

$$\lambda_k = \sigma_k + j\omega_k = \frac{\ln z_k}{\Delta t}, \quad |\omega_k| \Delta t < \pi. \quad (2.15)$$

La condición $|\omega_k| \Delta t < \pi$ es el criterio de Nyquist que garantiza la unicidad de la rama principal del logaritmo complejo en (2.15); las tasas de reporte PMU ($F_s \geq 30$ Hz) la satisfacen con amplio margen para la banda electromecánica ($f_k \leq 3$ Hz) [8]. A partir de las raíces z_k del polinomio de predicción se recuperan el amortiguamiento $\sigma_k = \text{Re}(\ln z_k)/\Delta t$, la frecuencia $\omega_k = \text{Im}(\ln z_k)/\Delta t$ y la razón de amortiguamiento ζ_k de (2.11).

Las variables del problema se clasifican en tres grupos. Las variables *medidas* son las P series de tiempo $\mathbf{x}_i \in \mathbb{C}^N$, con $\mathbf{x}_i = [x_i(0) \ x_i(1) \ \dots \ x_i(N-1)]^\top$. Las variables *de control* del algoritmo, fijadas a criterios heurísticos, son el orden de predicción L y el orden del modelo M . Las variables *estimadas* son los polos $\hat{s}_k$ y las amplitudes complejas $\hat{a}_{i,k}$; a partir de ellas se aproximan la frecuencia f_k , la razón de amortiguamiento ζ_k , las formas modales, los índices de participación y los cosenos directores.

2.3 ALGORITMO TUFTS-KUMARESAN MULTIVARIABLE (MULTI-TK)

2.3.1 MODELO DE SEÑAL Y PREDICCIÓN LINEAL HACIA ATRÁS

Para P canales medidos $\{x_i[n]\}_{i=1}^P$, cada una de N muestras ($n = 0, \dots, N-1$), el modelo de señal con ruido de medición $w_i[n]$ es

$$x_i[n] = \sum_{k=1}^M a_{i,k} z_k^n + w_i[n], \quad z_k = e^{(\sigma_k + j\omega_k)\Delta t}. \quad (2.16)$$

Se elige un orden de predictor L tal que $M \leq L \leq N - M$. Para cada i -ésimo canal se plantea el problema de **predicción lineal hacia atrás** de orden L :

$$\mathbf{A}_i \mathbf{b} = -\mathbf{h}_i, \quad (2.17)$$

donde $\mathbf{b} = [b(1), b(2), \dots, b(L)]^\top \in \mathbb{C}^{L \times 1}$ es el vector de coeficientes de predicción hacia atrás del polinomio característico y $\mathbf{h}_i = [x_i^*(0), x_i^*(1), \dots, x_i^*(N-L-1)]^\top \in \mathbb{C}^{(N-L) \times 1}$ es el vector objetivo de la predicción hacia atrás del polinomio característico.

La matriz de Hankel, conjugada para la i -ésima señal (el asterisco denota conjugación compleja) se construye desplazando las muestras y apilando los vectores desplazados, formando así una matriz donde los elementos a lo largo sus antidiagonales son constantes,

tomando la forma de:

$$\mathbf{A}_i = \begin{bmatrix} x_i^*(1) & x_i^*(2) & \cdots & x_i^*(L) \\ x_i^*(2) & x_i^*(3) & \cdots & x_i^*(L+1) \\ \vdots & \vdots & \ddots & \vdots \\ x_i^*(N-L) & x_i^*(N-L+1) & \cdots & x_i^*(N-1) \end{bmatrix} \in \mathbb{C}^{(N-L) \times L}. \quad (2.18)$$

La elección de la predicción *hacia atrás* sobre datos conjugados no es accidental: constituye el mecanismo de discriminación señal–ruido del método de Tufts–Kumaresan [2]. Al elegir un orden sobredimensionado $L > M$, el polinomio característico

$$B(z) = z^L + b(1)z^{L-1} + b(2)z^{L-2} + \cdots + b(L) = 0. \quad (2.19)$$

posee L raíces, de las cuales sólo M corresponden a raíces reales. En la formulación *hacia atrás*, las raíces de señal se ubican en los recíprocos conjugados de los polos, $1/z_k^*$: para modos amortiguados ($|z_k| < 1$) éstas quedan **fuera** del círculo unitario, mientras que las $L - M$ raíces extrañas inducidas por el ruido tienden a permanecer **dentro** de él [2], [9]. Esta separación geométrica en el plano z permite identificar los polos presentes en la señal de los polos espurios, propiedad de la que carece la predicción *hacia adelante* del método de Prony clásico [8], [10].

2.3.2 SISTEMA MULTICANAL

La contribución central de la formulación multivariable consiste en apilar las P matrices de Hankel individuales en una única matriz rectangular de gran tamaño y los vectores objetivo de todos los canales:

$$\mathbf{A}_{\text{multi}} = \begin{bmatrix} \mathbf{A}_1 \\ \mathbf{A}_2 \\ \vdots \\ \mathbf{A}_P \end{bmatrix} \in \mathbb{C}^{P(N-L) \times L}, \quad \mathbf{h}_{\text{multi}} = \begin{bmatrix} \mathbf{h}_1 \\ \mathbf{h}_2 \\ \vdots \\ \mathbf{h}_P \end{bmatrix} \in \mathbb{C}^{P(N-L) \times 1}. \quad (2.20)$$

El sistema completo de predicción lineal es:

$$\boxed{\mathbf{A}_{\text{multi}} \mathbf{b} = -\mathbf{h}_{\text{multi}}}. \quad (2.21)$$

El apilamiento vertical impone un *único* vector de coeficientes $\mathbf{b}$ —y por lo tanto un único conjunto de polos— a los P canales simultáneamente, lo que constituye la hipótesis física del método: los P registros son observaciones distintas de la misma dinámica global. Para que (2.21) esté sobredeterminado debe cumplirse $P(N-L) \geq L$ condición que mejora al aumentar el número de canales P .

2.3.3 DESCOMPOSICIÓN EN VALORES SINGULARES (SVD) Y SELECCIÓN DEL ORDEN DEL MODELO

Se aplica la **descomposición en valores singulares** a $\mathbf{A}_{\text{multi}}$:

$$\mathbf{A}_{\text{multi}} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^H, \quad (2.22)$$

cdonde $\mathbf{U} \in \mathbb{C}^{P(N-L) \times P(N-L)}$, $\mathbf{\Sigma} \in \mathbb{R}^{P(N-L) \times L}$ y $\mathbf{V} \in \mathbb{C}^{L \times L}$, y el superíndice H denota transpuesta conjugada. Los valores singulares $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_L \geq 0$ separan el subespacio de señal del subespacio de ruido.

El teorema de Eckart-Young-Mirsky [3], garantiza que $\mathbf{U}_s \mathbf{\Sigma}_s \mathbf{V}_s$ es la mejor aproximación de rango M a una matriz, en el sentido de mínimos cuadrados, es precisamente su SVD truncada, en este sentido cabe aclarar que la determinacion del rango es un problema mal planteado, pues una perturbacion numerica pequeña en matrices deficientes de rango, devuelve el rango completo, por lo que el enfoque es una aproximación de bajo rango sobre la matriz de datos formulada [11] [12].

Dado que el rango exacto no es un objeto estable bajo perturbaciones, se define el rango numerico de una matriz respecto a una tolerancia, a fijar a priori. Sea $\mathbf{A}_{\text{multi}} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^H$, entonces

$$\mathbf{U}_s \mathbf{\Sigma}_s \mathbf{V}_s^H = \arg \min_{\text{rank}(\mathbf{B}) \leq M} \|\mathbf{A}_{\text{multi}} - \mathbf{B}\|_F, \quad (2.23)$$

donde la norma de Frobenius de una matriz es la raíz de la suma de los cuadrados de todos sus elementos $\|\mathbf{A}\|_F = \sqrt{\sum_i^n \sum_j^m |A_{ij}|^2}$, y el error de aproximación queda cuantificado por la energía de los valores singulares descartados:

$$\|\mathbf{A}_{\text{multi}} - \mathbf{U}_s \mathbf{\Sigma}_s \mathbf{V}_s^H\|_F^2 = \sum_{k=M+1}^L \sigma_k^2. \quad (2.24)$$

Bajo el modelo $\mathbf{A}_{\text{multi}} = \mathbf{A}_{\text{real}} + \mathbf{A}_{\text{ruido}}$, donde $\text{rank}(\mathbf{A}_{\text{real}}) = M$ por construcción del modelo en el caso sin ruido (2.13), ya que con ruido de observación el rango efectivo excede M , los primeros M valores singulares aproximan el subespacio de señal y los restantes la contribución del ruido de medición; el truncamiento de rango M actúa entonces como un filtro ante el ruido en el sentido de (2.23) [2], [3]. El número de polos dominantes M se selecciona mediante el criterio de **energía acumulada** de los valores singulares de (2.22):

$$\hat{\sigma}_M = \frac{\sum_{k=1}^M \sigma_k^2}{\sum_{k=1}^r \sigma_k^2} \geq E_0, \quad (2.25)$$

E_0 es la tolerancia energetica, propuesta en funcion del nivel de ruido, que garantiza la retención de los polos reales durante el evento transitorio. Reteniendo el menor M tal que $\hat{\sigma}_M$ supere o iguale la tolerancia de energía preestablecido [3]. Con el orden M determinado, la SVD truncada de $\mathbf{A}_{\text{multi}}$ es:

$$\mathbf{A}_{\text{multi}} \approx \mathbf{U}_s \mathbf{\Sigma}_s \mathbf{V}_s^H, \quad \mathbf{U}_s \in \mathbb{C}^{P(N-L) \times M}, \quad \mathbf{\Sigma}_s \in \mathbb{R}^{M \times M}, \quad \mathbf{V}_s \in \mathbb{C}^{L \times M}. \quad (2.26)$$

y la solución del sistema es:

$$\mathbf{b} = - \sum_{k=1}^M \sigma_k^{-1} \left(\mathbf{u}_k^H \mathbf{h}_{\text{multi}} \right) \mathbf{v}_k, \quad (2.27)$$

donde $\mathbf{u}_k \in \mathbb{C}^{P(N-L) \times 1}$ y $\mathbf{v}_k \in \mathbb{C}^{L \times 1}$ son el k -ésimo vector singular izquierdo y derecho, respectivamente, y σ_k el k -ésimo valor singular. En forma compacta, $\mathbf{b} = -\mathbf{V}_s \mathbf{\Sigma}_s^{-1} \mathbf{U}_s^H \mathbf{h}_{\text{multi}}$. La ecuación (2.27) es la solución de mínimos cuadrados mediante la **pseudoinversa de Moore–Penrose** de la matriz de datos [3]:

$$\mathbf{b} = -\mathbf{A}_{\text{multi}}^{+(M)} \mathbf{h}_{\text{multi}}, \quad \mathbf{A}_{\text{multi}}^{+(M)} = \mathbf{V}_s \mathbf{\Sigma}_s^{-1} \mathbf{U}_s^H. \quad (2.28)$$

$\mathbf{A}_{\text{multi}}$ Y $\mathbf{h}_{\text{multi}}$ estan contruidas con las mismas muestras contaminadas de ruido de las señales, por lo que el ruido introduce sesgos en el paso lineal. Esta solución posee una doble optimalidad [3]: minimiza el residuo $\|\mathbf{A}_{\text{multi}} \mathbf{b} + \mathbf{h}_{\text{multi}}\|_2$ restringido al subespacio de señal de rango M y, entre todas las soluciones que lo logran, es la de mínima norma $\|\mathbf{b}\|_2$. Ambas optimalidades se enuncian bajo la hipótesis de que la matriz de datos es exacta.

El truncamiento cumple además una función espesifica: en la pseudoinversa completa, los valores singulares pequeños asociados al ruido aparecen invertidos (σ_k^{-1} grande) y amplifican catastróficamente la componente de ruido de $\mathbf{h}_{\text{multi}}$; al retener sólo $\mathbf{\Sigma}_s$, dicha amplificación se elimina y la varianza del estimador de $\mathbf{b}$ se reduce drásticamente [2], [3].

2.4 UNA APROXIMACIÓN A LOS PATRONES DINÁMICOS

2.4.1 ESTIMACIÓN DE AMPLITUDES COMPLEJAS

Una vez identificados los polos, la etapa final consiste en determinar la contribución de cada modo en cada canal. Evaluando (2.13) sin ruido para las N muestras del canal i se obtiene el sistema lineal, conocidos los polos $\{z_k\}_{k=1}^M$, para cada canal i se resuelve:

$$\mathbf{x}_i = \mathbf{\Psi} \mathbf{B}_i, \quad (2.29)$$

$$\mathbf{x}_i = \underbrace{\begin{bmatrix} z_1^0 & z_2^0 & \cdots & z_M^0 \\ z_1^1 & z_2^1 & \cdots & z_M^1 \\ \vdots & & \ddots & \vdots \\ z_1^{N-1} & z_2^{N-1} & \cdots & z_M^{N-1} \end{bmatrix}}_{\Psi} \begin{bmatrix} B_{i,1} \\ B_{i,2} \\ \vdots \\ B_{i,M} \end{bmatrix} \quad (2.30)$$

donde $\Psi \in \mathbb{C}^{N \times M}$ es la matriz de Vandermonde construida con las raíces estimadas y $\mathbf{B}_i \in \mathbb{C}^{M \times 1}$ el vector de amplitudes complejas desconocidas del canal i . Mediante mínimos cuadrados:

$$\mathbf{B}_i = \Psi^+ \mathbf{x}_i = (\Psi^H \Psi)^{-1} \Psi^H \mathbf{x}_i \quad (2.31)$$

La matriz $\Psi \in \mathbb{C}^{N \times M}$ es una matriz de **Vandermonde** construida sobre los polos estimados. En la práctica, la solución vía ecuaciones $(\Psi^H \Psi)^{-1} \Psi^H$ se aconseja evitarse: cuando el sistema presenta modos de frecuencias cercanas los nodos z_k se aglomeran y Ψ se vuelve mal condicionada, y el producto $\Psi^H \Psi$ eleva al cuadrado su número de condición, $\kappa(\Psi^H \Psi) = \kappa(\Psi)^2$. La alternativa numéricamente estable es la pseudoinversa calculada mediante la SVD de Ψ [3]:

$$\mathbf{B}_i = \mathbf{V}_\Psi \Sigma_\Psi^{-1} \mathbf{U}_\Psi^H \mathbf{x}_i, \quad \Psi = \mathbf{U}_\Psi \Sigma_\Psi \mathbf{V}_\Psi^H. \quad (2.32)$$

Puesto que Ψ es *común a todos los canales*, las P soluciones se obtienen en un solo paso resolviendo

$$\mathbf{B} = \Psi^\dagger \mathbf{X}, \quad \mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \cdots \ \mathbf{x}_P], \quad (2.33)$$

con $\mathbf{X} \in \mathbb{C}^{N \times P}$, $\mathbf{B} \in \mathbb{C}^{M \times P}$ y $\Psi^\dagger \in \mathbb{C}^{M \times N}$ la pseudoinversa. De cada elemento $B_{k,i}$ se extraen la amplitud y la fase del modo k en el canal i :

$$|a_{i,k}| = |B_{k,i}|, \quad \phi_{i,k} = \arg(B_{k,i}). \quad (2.34)$$

En la práctica, la magnitud $a_{i,k}$ se usa para medir cuanto participa un modo de oscilación en las mediciones (o viceversa), mientras que la fase $\phi_{i,k}$ nos permite medir la actividad del modo oscilatorio en las señales medidas. Por lo tanto, la magnitud y la fase son empleadas para determinar modos shapes y las magnitudes son utilizadas para proporcionar un índice de participación.

2.4.2 DISCRIMINACIÓN DE MODOS DOMINANTES POR ENERGÍA MODAL

Los estimadores con orden sobredimensionado (Multi-TK con $L > M$, VarPro con modos triviales adicionales para absorber ruido) entregan un conjunto de modos en el que

los modos físicos dominantes están mezclados con modos triviales. Para separarlos, además del criterio sobre valores singulares (2.25), se emplea el criterio de **energía modal** sobre las amplitudes estimadas [6]: la energía del modo k se define a partir de las amplitudes complejas de todos los canales,

$$E_k = \sum_{i=1}^P |a_{i,k}|^2 = \|\varphi_k\|_2^2, \quad (2.35)$$

y los modos se ordenan por energía decreciente. El peso de energía acumulada

$$E_{s,k} = \frac{\sum_{i=1}^k E_i}{\sum_{i=1}^M E_i} \times 100 \% \quad (2.36)$$

determina los k primeros modos como dominantes cuando $E_{s,k} \geq E_0$, con $E_0 = 85 \%$ como valor validado empíricamente frente al análisis de eigenvalores y a la densidad espectral de potencia en el sistema de prueba de 16 generadores y 68 buses [6]. A diferencia de (2.25), que opera sobre el subespacio de la matriz de datos *antes* de estimar los polos, el criterio (2.36) opera sobre la contribución de cada modo ya estimado a la reconstrucción de las señales, por lo que ambos criterios son complementarios: el primero fija el orden del modelo M y el segundo jerarquiza los modos físicos dentro de ese orden.

2.4.3 FORMA MODAL (MODE SHAPE)

La **forma modal** del modo k aproxima la distribución espacial:

$$\varphi_k = \begin{bmatrix} a_{1,k} \\ a_{2,k} \\ \vdots \\ a_{P,k} \end{bmatrix} = \begin{bmatrix} |a_{1,k}| e^{j\phi_{1,k}} \\ |a_{2,k}| e^{j\phi_{2,k}} \\ \vdots \\ |a_{P,k}| e^{j\phi_{P,k}} \end{bmatrix} \in \mathbb{C}^{P \times 1}. \quad (2.37)$$

La magnitud $|\varphi_k|$ indica observabilidad del modo en la medición; la fase $\angle \varphi_k$ revela relaciones entre señales. Para comparar formas modales entre modos, φ_k se normaliza a norma unitaria, $\hat{\varphi}_k = \varphi_k / \|\varphi_k\|_2$, o respecto a su componente de mayor magnitud, convención empleada en la literatura de identificación basada en mediciones [6], [7] se usa la componente de mayor magnitud tal que:

$$\hat{\varphi}_k = \frac{\varphi_k}{|\varphi_k|_{\max}}, \quad |\varphi_k|_{\max} = \max_{1 \leq i \leq P} |a_{i,k}|, \quad (2.38)$$

de manera que $|\hat{\varphi}_{i,k}| \in [0, 1]$. Agrupando los K modos se forma la matriz de formas

modales

$$\mathbf{\Phi} = [\hat{\phi}_1 \ \hat{\phi}_2 \ \cdots \ \hat{\phi}_K] = \begin{bmatrix} \hat{\phi}_{1,1} & \hat{\phi}_{1,2} & \cdots & \hat{\phi}_{1,K} \\ \hat{\phi}_{2,1} & \hat{\phi}_{2,2} & \cdots & \hat{\phi}_{2,K} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\phi}_{P,1} & \hat{\phi}_{P,2} & \cdots & \hat{\phi}_{P,K} \end{bmatrix} \in \mathbb{C}^{P \times K}, \quad (2.39)$$

La forma modal empírica ϕ_k tiene una interpretación si se toma la interpretación en términos del modelo de estados (2.8): por (2.12), $a_{i,k} = (\mathbf{c}_i^\top \boldsymbol{\phi}_k) c_k$, de modo que

$$\mathbf{s}_k = c_k \begin{bmatrix} \mathbf{c}_1^\top \boldsymbol{\phi}_k \\ \vdots \\ \mathbf{c}_P^\top \boldsymbol{\phi}_k \end{bmatrix}, \quad (2.40)$$

es decir, $\mathbf{s}_k$ es la proyección del **eigenvector derecho** $\boldsymbol{\phi}_k$ sobre los canales medidos, escalada por el factor de excitación c_k , común a todos los canales. Dado que c_k es un escalar, las magnitudes *relativas* y las fases *relativas* entre canales de $\mathbf{s}_k$ coinciden con las del eigenvector derecho, que es precisamente la forma modal del análisis de pequeña señal [1]. En particular, los canales en contrafase ($\Delta\phi \approx 180^\circ$) identifican los grupos coherentes de generadores que oscilan uno contra otro en un modo interárea.

2.4.4 ÍNDICES DE PARTICIPACIÓN

De la matriz de modos shape se define el índice de participación del canal i en el modo k como la magnitud normalizada

$$p_{i,k} = |\hat{\phi}_{i,k}| = \frac{|a_{i,k}|}{|\boldsymbol{\phi}_k|_{\max}} \in [0, 1], \quad (2.41)$$

que da lugar a la matriz de índices de participación

$$\mathbf{P} = [p_{i,k}] \in \mathbb{R}^{P \times K}. \quad (2.42)$$

Un valor $p_{i,k} \rightarrow 1$ indica que el modo k es altamente observable en la medición i , mientras que $p_{i,k} \rightarrow 0$ indica que el modo prácticamente no se manifiesta en ese canal. Debe distinguirse $\hat{p}_{ik}$ del **factor de participación** del análisis de pequeña señal, definido como el producto de los elementos de los eigenvectores derecho e izquierdo,

$$p_{ki} = \phi_{ki} \psi_{ik}, \quad (2.43)$$

que mide la participación neta del estado k en el modo i combinando actividad (eigenvector derecho) y controlabilidad de la condición inicial (eigenvector izquierdo), y cuya evaluación exige el conocimiento explícito de la matriz $\mathbf{A}$ [1]. El índice $\hat{p}_{ik}$ aquí propuesto es,

en cambio, una medida *empírica de observabilidad relativa* del modo k en el canal i , calculable exclusivamente a partir de mediciones sincrofasoriales sin requerir un modelo del sistema. Ambas nociones coinciden en su uso práctico: jerarquizar las señales (y por ende las máquinas o áreas) dominantes en cada modo e identificar los grupos coherentes de generadores, lo que habilita la localización de los canales óptimos para monitoreo y control de oscilaciones [8]. Esta distinción está respaldada por la literatura de identificación basada en mediciones: los métodos que estiman explícitamente una realización de estado (p. ej. ERA) recuperan el factor de participación formal a partir de los eigenvectores derecho e izquierdo de la matriz de estados realizada [7], mientras que los métodos de ajuste de amplitudes (OptVarPro, Prony multicanal, Multi-TK) construyen índices de participación a partir de las magnitudes $|a_{i,k}|$ [6]. En ambos enfoques se ha verificado, sobre el sistema de prueba de 16 generadores y 68 buses, que los generadores con mayor índice empírico coinciden con los de mayor factor de participación obtenido por análisis de eigenvalores, aun cuando los valores numéricos difieren [6], [7].

2.4.5 IDENTIFICACIÓN DE GRUPOS COHERENTES: COSENO DIRECTOR Y AGRUPAMIENTO ESPECTRAL

La forma modal de un solo modo separa a los generadores en, a lo sumo, dos grupos en contrafase; la partición del sistema en grupos coherentes bajo la acción conjunta de *múltiples* modos dominantes requiere una medida de similitud entre generadores construida sobre el conjunto completo de formas modales [6], [13]. Sea $\mathbf{g}_i \in \mathbb{C}^{K \times 1}$ la transpuesta de la i -ésima fila de Φ ,

$$\mathbf{g}_i = [\hat{\varphi}_{i,1} \ \hat{\varphi}_{i,2} \ \cdots \ \hat{\varphi}_{i,K}]^T, \quad (2.44)$$

es decir, la *firma modal* del canal i en el espacio de los K modos. En [7] el coseno director entre los canales i y j se define, para formas modales reales, como

$$d_{ij} = \frac{\sum_{h=1}^K \varphi_{ih} \varphi_{jh}}{\sqrt{\sum_{h=1}^K \varphi_{ih}^2 \sum_{h=1}^K \varphi_{jh}^2}}. \quad (2.45)$$

Puesto que las amplitudes obtenidas en (2.34) son complejas y de fase arbitraria, en este trabajo se emplea la extensión

$$d_{ij} = \frac{\text{Re}(\mathbf{g}_i^H \mathbf{g}_j)}{\|\mathbf{g}_i\|_2 \|\mathbf{g}_j\|_2} \in [-1, 1], \quad (2.46)$$

que preserva la interpretación geométrica de (2.45) —el coseno del ángulo entre las firmas modales de ambos canales— y se reduce exactamente a ella cuando todas las componentes $\hat{\varphi}_{ih}$ son reales, esto es, cuando las fases modales son 0° o 180° . La parte real

del producto interno hermitiano es necesaria para que d_{ij} sea una cantidad real y simétrica; su uso equivale a proyectar la firma modal de un canal sobre la del otro.

Evaluando (2.46) para todos los pares se forma la matriz de cosenos directores


$$\mathbf{d} = \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1P} \\ d_{21} & d_{22} & \cdots & d_{2P} \\ \vdots & \vdots & \ddots & \vdots \\ d_{P1} & d_{P2} & \cdots & d_{PP} \end{bmatrix} \in \mathbb{R}^{P \times P}, \quad (2.47)$$

simétrica y con diagonal unitaria, $d_{ii} = 1$. La interpretación física es directa: cuando la diferencia angular entre dos generadores es 0° , ambos son completamente coherentes y $d_{ij} = 1$; conforme dicha diferencia crece hacia $\pm 180^\circ$, d_{ij} decrece monotónicamente hasta -1 , valor que corresponde a incoherencia total.

$$d_{ij} \geq 0,8, \quad (2.48)$$

y los grupos coherentes se identifican como los bloques de la matriz $\mathbf{d}$ que satisfacen (2.48). La representación de $\mathbf{d}$ como mapa de calor permite reconocer visualmente dichos bloques sin requerir información *a priori* sobre el número de grupos.

2.5 METODOLOGÍA PROPUESTA



2.6 SEÑALES DE PRUEBA SINTÉTICAS

Tabla 2.1: Parámetros modales del banco de señales.

f [Hz]	ζ [%]
0.2349	7.65
0.5505	7.84
0.6062	9.43
0.6609	5.26
0.7840	11.95
0.9691	8.88
1.0598	8.68
1.2603	11.83
1.3494	9.03
1.3919	8.38
1.4437	2.81
1.5104	6.49
1.6206	8.19
2.4454	9.36
2.6533	14.25
3.4528	5.78




Figura 2.2: Señales de prueba sintéticas.




Figura 2.3: Distribución de los valores propios de las señales de prueba.




Figura 2.4: Plano Z de los valores propios de las señales de prueba.

2.6.1 ROBUSTEZ FRENTE AL RUIDO DE MEDICIÓN

El modelo de señal (2.16) incorpora explícitamente un término de ruido de medición $w_i[n]$ cuyo efecto sobre la exactitud de $\hat{f}_k$, $\hat{\zeta}_k$ y $\hat{a}_{i,k}$ se cuantifica a continuación, evaluando el algoritmo completo (Multi-TK + selección de orden del modelo/truncamiento de la SVD + estimación de los parámetros modales) sobre el banco de señales sintéticas variando la relación señal-ruido (SNR).




Figura 2.5: Truncamiento de la svd mediante los metodos propuestos.




Figura 2.6: Errores por cada parametro estimado.

2.6.2 MAXIMO DE MODOS CERCANOS RESOLUBLES (LÍMITE DE RESOLUCIÓN)

La capacidad de multi-TK para distinguir dos modos de frecuencia cercananas estan acotadas por la duracion de la ventana de datos anlizada, independientemente del algoritmo de estimacion, se determina una diferencia en frecuencia minima Δf para determinar si los modos cercanos son resolubles, es decir, si el algoritmo puede estimarlos, se determina Δf en funcion del amortiguamiento, los nivels de SNR y el orden de prediccion L :

2.6.3 EFECTO EN EL NUMERO DE CANALES

En la seccion subsec:Sis_Mul

2.6.4 SENSIBILIDAD AL ORDEN DEL PREDICTOR L

2.6.5 DE PARAMÉTRICO A NO PARAMÉTRICO: COMPARACIÓN DE LOS CRITERIOS DE TRUNCAMIENTO DE LA SVD

REFERENCIAS

- [1] P. Kundur, *Power System Stability and Control* (EPRI Power System Engineering Series). New York: McGraw-Hill, 1994.
- [2] R. Kumaresan y D. W. Tufts, «Estimating the Parameters of Exponentially Damped Sinusoids and Pole-Zero Modeling in Noise,» *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 30, n.º 6, págs. 833-840, 1982. DOI: 10.1109/TASSP.1982.1163974
- [3] S. L. Brunton y J. N. Kutz, *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*, 2.ª ed. Cambridge: Cambridge University Press, 2022.
- [4] M. Gavish y D. L. Donoho, «The Optimal Hard Threshold for Singular Values is $4/\sqrt{3}$,» *IEEE Transactions on Information Theory*, vol. 60, n.º 8, págs. 5040-5053, 2014. DOI: 10.1109/TIT.2014.2323359
- [5] T. Askham y J. N. Kutz, «Variable Projection Methods for an Optimized Dynamic Mode Decomposition,» *SIAM Journal on Applied Dynamical Systems*, vol. 17, n.º 1, págs. 380-416, 2018. DOI: 10.1137/M1124176
- [6] T. Jiang, X. Kou, G. Liu y H. Yuan, «Synergistic Data Analytics for Electromechanical Oscillation in Electric Power Systems,» *International Journal of Electrical Power and Energy Systems*, vol. 135, págs. 107 610, 2022. DOI: 10.1016/j.ijepes.2021.107610
- [7] X. Li et al., «An Eigensystem Realization Algorithm Based Data-Driven Approach for Extracting Electromechanical Oscillation Dynamic Patterns from Synchrophasor Measurements in Bulk Power Grids,» *International Journal of Electrical Power and Energy Systems*, vol. 116, págs. 105 549, 2020. DOI: 10.1016/j.ijepes.2019.105549
- [8] P. W. Sauer, M. A. Pai y J. H. Chow, *Power System Dynamics and Stability: With Synchrophasor Measurement and Power System Toolbox*, 2.ª ed. Hoboken, NJ: Wiley-IEEE Press, 2017.
- [9] J. Marple S. Lawrence, *Digital spectral analysis*, 2.ª ed. Mineola, New York: Dover Publications, Inc., 2019.
- [10] J. F. Hauer, C. J. Demeure y L. L. Scharf, «Initial Results in Prony Analysis of Power System Response Signals,» *IEEE Transactions on Power Systems*, vol. 5, n.º 1, págs. 80-89, 1990. DOI: 10.1109/59.49090

- [11] I. Markovsky, *Low-Rank Approximation: Algorithms, Implementation, Applications*, 2.^a ed., A. Isidori, ed. Brussels, Belgium: Springer International Publishing AG, 2019.
- [12] A. C. Antoulas, *Approximation of Large-Scale Dynamical Systems*, 1.^a ed., R. C. Smith, ed. Philadelphia: Society for Industrial y Applied Mathematics, 2005.
- [13] X. Li, H. Cui, T. Jiang, Y. Xu, H. Jia y F. Li, «Multichannel continuous wavelet transform approach to estimate electromechanical oscillation modes, mode shapes and coherent groups from synchrophasors in bulk power grids,» *International Journal of Electrical Power and Energy Systems*, vol. 96, págs. 222-237, 2018.

CAPITULO 3

RESULTADOS

RESUMEN

